

vLLM北京峰会 · 2026

从ChatGPT到OpenClaw

构建普适、普惠的AI计算新基础设施

From ChatGPT to OpenClaw: Building a New Infrastructure for
Ubiquitous, Inclusive, and Trusted AI Computing

林咏华


Yonghua Lin

北京智源人工智能研究院

Beijing Academy of Artificial Intelligence

AI的角色之变：从ChatGPT到OpenClaw —— 从副驾驶变成主驾驶

From ChatGPT to OpenClaw, the role of AI has changed from "assisted decision-making" to "execution system"



- 人工智能的能力，从单一靠“模型”决定，演变到由“模型 + Agent系统 + Skills”共同决定
- 专业领域的人工智能能力打造，行业落地范式也发生重要演变

• 行业落地：打造**微调数据** -> 打造**专业知识库** -> 打造**专业领域的Skill**

Industry Implementation: Data Fine-tuning → Domain Knowledge Base → Specialized Skills

人工智能三年来的算力需求演进：在智能体系统的拉动下，推理算力激增

The Evolution of Computing Power Demand in AI Over the Past Three Years: Inference Computing Power Surges Driven by Agentic Systems

算力是“研发资本”

阶段一（2023 ~2024）
基础模型 + 微调（SFT 时代）

行业特征

- 企业主要投入在微调实验
- 推理主要是助手型应用
- 并发低、持续性低

Global AI compute demands

Training: 75%~85%

Inference: 15%~25%

算力是“业务基础设施”

阶段二（2024~2025）
基础模型 + RAG

行业特征

- 推理成本大幅下降（>100倍）
- 企业大规模部署知识问答系统
- SaaS化调用开始爆发

Global AI compute demands

Training: 55%~65%

Inference: 35%~45%

算力是“生成资料”

阶段三（2026）
Agent / OpenClaw 时代

行业特征

- 多步推理（一次任务 ≈ 5-20 次推理调用）
- 24/7 常驻 Agent
- 高频业务自动执行

Global AI compute demands

Training: 30%~40%

Inference: 60%~70%

当AI成为业务系统的“主驾驶”

我们需要什么样的计算基础设施？

基础设施又如何与智能体系统共生演进？

第一部分

新范式下的新挑战

我们面对的三个"分裂"



芯片架构的分裂

从"单一"到"百花齐放"



算子语言的分散

从"统一"到"战国时代"



框架与算法的繁杂

$N \times M$ 的乘法难题

持续的突破创新：不是暂时的分化，而是永恒的演进

商用AI芯片架构图谱

 通用GPU路线
NVIDIA · AMD

架构: SIMT + 可编程
优势: 算法泛化性最强
代价: 功耗高, 利用率低
场景: 云端训练

2026: Feynman架构(1.6nm+硅光子), Rubin平台, LPU推理芯片

 DSA专用路线
昇腾 · 寒武纪 · TPU

架构: 脉动阵列 + 数据流
优势: 矩阵乘法极致高效
代价: 灵活度低
场景: 规模化推理

2026: 下一代达芬奇核心, 3D堆叠显存

 GPGPU自主路线
沐曦 · 天数 · 摩尔线程

架构: 类CUDA + 自主指令
优势: CUDA生态兼容
代价: 工具链待完善
场景: 国产替代

2026: 多厂商集体迭代升级

 RISC-V AI路线
Meta MTIA · Tenstorrent

架构: RVV向量扩展 + 自定义
优势: 自由定制, 成本↓40-60%
代价: 生态从零开始
场景: 垂直行业定制

2026: Meta MTIA 3 Q3量产, 200 TFLOPS

前沿芯片架构探索

 存算一体

两条路线
模拟式 数字式
模拟: 睿科ReRAM, 55nm, 14-135 token/s
数字: 南科大STT-MRAM, 精度无损
挑战: 算子库完全重构

 光子计算

西电: 16通道, 320ps时延, 1.39 TOPS/W
Q.ANT: 已部署超算中心, 吞吐量↑50倍
挑战: 模拟计算精度模型

 3D堆叠

博通XDSiP: 3.5D封装, 面对面3D-IC
Imec 2.0: 细粒度晶圆堆叠
睿科: ReRAM-on-Logic, 32MB, 102.4GB/s
挑战: 存储层次感知编译

 量子+AI

趋势: NVIDIA GTC 2026宣布加速"量子+AI"融合
目标: 2028年前实用级融合系统
挑战: 编程模型完全不同

算子开发语言百花齐放，语言生态分裂


模型算法百花齐放，开发算子的工程师数量持续增多

技术路线分叉：全球支持跨芯的开源算子语言上除了Triton之外，2025年出现了包括Tilelang、Gluon、Helion、TLX、CuteDSL、cuTile等面向不同用户需求的多种新的算子编程语言。算子库随着语言多样性的出现，将产生各种“小、散、多”的新问题，阻碍了统一生态的建设。

各种语言基于不同的编译器基础系统，芯片厂商需要从一种编译器生态，适配到另有一种生态

- Triton, Gluon, Helion, TLX: Triton-lang compiler
- CuteDSL, cuTile, CUDA C: CUDA compiler
- Tilelang: TVM

From Triton 2025 conference, OpenAI



是否可以拓展Triton语言，覆盖不同“性能” vs. “优化”的需求，且保留现有10多个芯片厂商无需生态迁移？

框架与算法繁杂：以10000个头部模型为例，依赖的算法/框架库众多

语言领域

模型数量: 5919

库	频次
torch	5853
vllm	1111
accelerate	876
peft	551
triton	455
sglang	441
bitsandbytes	342
flash-attn	320
einops	235
deepspeed	227
text-generation-inference	190
tgi	170
torchvision	158
tensorflow	144

视觉多模态领域

模型数量: 2789

库	频次
torch	2710
accelerate	569
torchvision	563
diffusers	526
einops	404
timm	335
opencv-python	326
peft	293
vllm	186
deepspeed	173
bitsandbytes	151
torchaudio	123
onnxruntime	122
einops-exts	107
torchmetrics	105

音频领域

模型数量: 582

库	频次
torch	535
torchaudio	133
accelerate	84
einops	60
triton	47
torchvision	44
diffusers	30
bitsandbytes	33
llvmlite	23
peft	26
lightning	24
deepspeed	17
x_transformers	20
trainer	16
ema_pytorch	16
onnxruntime	21

科学计算领域

模型数量: 114

库	频次
torch	101
einops	13
torchvision	13
accelerate	12
peft	8
timm	6
torchaudio	5
flash-attn	5
pytorch-lightning	4
torcheval	4
bitsandbytes	4
triton	4
vllm	4
deepspeed	3
xformers	3
flash_attn	4

检索增强领域

模型数量: 596

库	频次
torch	592
accelerate	33
vllm	19
peft	38
flash_attn	21
deepspeed	7
flash-attn	9
pytorch-lightning	5
tensorflow	5
bitsandbytes	4
einops	4
ray	4
gguf	3
torchvision	3
pytorch	3
faiss-gpu	3

库	CUDA算子数
Torch	2921
Tensorflow	333
Vllm	120
Sglang	110
Flash-attn	37
bitsandbytes	77
xformers	9
Deepspeed	130
Peft	7
Torchaudio	6
Torchvision	15
Transformer-eng	73
onnxruntime-gpu	264
Torchao	16
Torchcodec	20
Funasr	4
mmcv	113
llama-cpp-python	116
torch-scatter	20
faiss-gpu	74
Text-gen-infer	9
Cublas	2668
Cudnn	6724
Cufft	2
Mxnet	789
Flashinfer-python	92
Colossalai	31
Cpm-kernel	59

算子库 + 算法/框架库是支撑海量模型的算法基础层。

挑战：如何把算子库接入到众多算法/框架库中，并面向多种芯片形成长期可维护？

此处的框架库的信息，来源于代码仓库的README文件，框架库全及不全，对库/算子库的统计。因此，上表仅供参考即可。

第二部分

FlagOS的解题之道


从" $N \times M$ "到" $N + M$ "



全球支持芯片种类最多的AI系统软件栈



打造AI计算的普适、普惠



算子库、编译器：解决芯片架构、编程语言的分裂问题

FlagGems是全球支持芯片数量最多的大模型开源算子库

芯片支持



16

厂商数量

25

芯片型号

支持25种AI芯片，覆盖16家主流AI芯片厂商

部分厂商及芯片列表

厂商	型号
华为昇腾	910B、910C
寒武纪	MLU系列
海光	K100、BW1000
昆仑芯	P800等
摩尔线程	S4000、S5000
清微智能	TX81
燧原	T20、T21
算能	SG2044
曦望	型号未知
太初	型号未知
ARM China	周易NPU
ARM	arm v9

英伟达 A100、A800、H100

FlagGems大模型算子库超过407个算子



全球最大Triton算子库，已进入PyTorch基金会生态

- FlagGems 成为PyTorch基金会生态合作项目
- 已支持18个 vLLM 的重要融合算子

性能表现



性能中位数
83%+ 各平台均超过80%

在AI系统领域，跨平台算子库达到原生算子80%以上的性能，就意味着可以投入生产。FlagGems在各种硬件平台上的性能中位数都超过83%——这标志着用Triton写高性能算子这条路已走通。

各平台性能对比（相对各芯片原生算子）

海光	天数	摩尔	沐曦	英伟达	昆仑	寒武纪
111%	107%	103%	102%	83%	84%	81%

推理任务算子覆盖度

40个主流模型的推理任务算子覆盖度达到90%~100%



新增6大领域算子库（下周发布）



FlagOS算子库的领域化扩展(1+6)，标志着AI系统软件栈从'大模型专用'走向'科学计算全领域覆盖'

FlagDNN

深度神经网络
10个

FlagBLAS

基础线性代数
30个

FlagFFT

快速傅里叶变换
2个

FlagSparse

稀疏矩阵
22个

FlagTensor

张量运算
18个

FlagAudio

语音
8个


90
累计算子数

6
领域数量

聚合“N”种AI芯片、支持多语言层次的统一编译器：FlagTree

解决芯片架构分裂的难题，聚合“N”种芯片

FlagTree 0.3 统一支持12家厂商的20种芯片




支持厂商：华为昇腾、寒武纪、海光、昆仑芯、摩尔线程、清微智能、沐曦、ARM中国（周易）、天数智芯、曦望、英伟达、算能等


解决语言生态分裂的难题

FlagTree 0.4: 支持多语言层次的统一多

芯片编译器 —— 预览支持Triton-TLE



Triton-TLE是对原有triton语言的全面扩展，
让单点的语言能力拓展到一个可以兼顾高性能、高开发效率与多硬件适配的更广阔的多维



聚合“N”种AI芯片的统一编译器：FlagTree v0.4


例子1：DSA 算子一行代码提升 16% 性能：

```
...
kv_ptr = kv_base + offs_d[:, None]*stride_kvd +
kv_ids[None, :]*stride_kvn
kv_msk = mask_d[:, None] & mask_ids[None, :]
kv_blk = tl.load(kv_ptr, kv_msk, other=0.0) #[DP, BK]
kv_blk = tle.load_async(kv_ptr, kv_msk, other=0.0) #[DP,
BK]
tkv_ptr = tkv_base + offs_td[:, None]*stride_kvd +
kv_ids[None, :]*stride_kvn
...
```


例子2：TLE 应用于关键算子 MoE Align Block Size, 获得最高接近CUDA的4倍性能

小 token 规模任务场景：
tle_cluster_fused 更占优

大 token 规模任务场景：
atomic_fused 方案表现最优




例子3：TLE应用于关键算子 TopK



测试环境：NV H800, Triton 3.5.0, TileLang 0.1.8, 单位：ms (数值越小越好)

例子4：TLE应用于华为昇腾，达到Ascend C的原生性能



统一多芯片插件系统：解决各种框架、算法包的适配问题


每家芯片厂商对 vLLM 的改动，都在沿着不同位置、不同方式去“魔改框架”。



- 厂商把 vLLM 原生调用改成厂商各自定义的不同算子，不只是“换了算子”，每家算子的参数表都不同。
- 每个厂商修改的张量布局、shape、KV cache 组织方式不统一
- 当每个厂商不是“全支持”时，在框架里显式关掉不支持的路径，用各自方式裁剪掉不同能力
- 调度策略与执行流程各自修改，不同芯片的最优执行路径并不一致。
- 各个厂商对通信栈与并行策略进行各自的修改，接入自己的通信库，增加all-to-all或EP/ETP, 替换自有的all_reduce等
- 各自进行Graph / stream / runtime / worker / loader 等平台运行时改造。
- 各个厂商对模型结构、量化、特性支持的定制扩展

FlagScale打造多芯片插件体系：为“M”个算法包提供多芯片“插入”能力

FlagScale多芯片多框架统一插件体系：是把“NxM”变为“N+M”的关键技术。通过插件方式，对框架/算法包实现非侵入式修改，**极大降低适配成本**，助力大模型Day0支持；**保持用户使用习惯**，无缝获得跨芯一致性结果




华为、平头哥、清微、摩尔、沐曦、海光、昆仑芯等已经接入：每个厂商的“首次”算法包/框架的接入时间从1个月缩短到1周。使用了该算法包/框架的新模型，只要算子能覆盖，即可做到“0”天迁移到国产芯片。

众智FlagOS的并行框架FlagScale：实现训练、微调、压缩到推理部署全流程覆盖，已支持英伟达、天数、沐曦、昆仑芯、寒武纪、海光、华为昇腾、摩尔线程、清微智能等9种芯片，集成了vLLM、SGLang、llama.cpp等多后端。<https://github.com/flagos-ai/FlagScale>

基于FlagScale的统一多芯片插件系统已经支持了主流深度学习框架、训练推理加速框架、强化学习框架

vLLM-Plugin-FL推理插件


<https://github.com/flagos-ai/vllm-plugin-FL>



- 已完成Qwen3-4B、Qwen3-32B、Qwen3-next、Qwen3.5-397B、Qwen3.5-35B、GLM5、DeepSeek3.2等重要模型的支持，性能无额外损耗。
- 已支持了华为、沐曦、平头哥、摩尔线程、天数、清微智能、海光、英伟达等芯片。


Megatron-LM-FL + TransformerEngine-FL训练插件

<https://github.com/flagos-ai/Megatron-LM-FL>
<https://github.com/flagos-ai/TransformerEngine-FL>




- 实现Nvidia、海光、沐曦、昆仑芯、寒武纪、天数等芯片上端到端训练。

PyTorch-FL 深度学习插件（进行中）



- 与PyTorch OpenReg合作打造多芯片统一插件

VeRL-FL 强化学习插件（进行中）



- 目前仅支持GPU和华为NPU，新增一款硬件需要侵入修改VeRL代码，代价高。
- 与字节合作基于Megatron-LM-FL和vllm-plugin-FL，实现多芯片的扩展，不再侵入VeRL代码。

每家芯片厂商对 vLLM 的改动，都在沿着不同位置、不同方式去“魔改框架”。 😞

- 厂商把 vLLM 原生调用改成厂商各自定义的不同算子，不只是“换了算子”，每家算子的参数表都不同。
- 每个厂商修改的张量布局、shape、KV cache 组织方式不统一
- 当每个厂商不是“全支持”时，在框架里显式关掉不支持的路径，用各自方式裁剪掉不同能力
- 调度策略与执行流程各自修改，不同芯片的最优执行路径并不一致。
- 各个厂商对通信栈与并行策略进行各自的修改，接入自己的通信库，增加all-to-all或EP/ETP, 替换自有的all_reduce等
- 各自进行Graph / stream / runtime / worker / loader 等平台运行时改造。
- 各个厂商对模型结构

FlagOS技术栈的 vLLM-plugin-fl 统一插件

<https://github.com/flagos-ai/vllm-plugin-FL>

- 统一算子分发与注册机制 + 多芯片统一算子库
FlagGems
- 基于统一的FlagTree编译器，通过FLIR统一中间表示，兼容多种硬件后端的张量布局和内存组织方式。
- 提供插件化能力裁剪与芯片配置管理
- 统一调度策略 + 自动性能调优
- 基于FlagCX统一通信库

通过“统一算子注册 + 统一编译器 + 统一通信库 + 插件化架构 + 自动调优 + 模型迁移工具”，实现了对多芯片“魔改”问题的系统级抽象与兼容，真正做到一次开发、多芯片运行。

下一步：集成 vLLM-IR 的能力，更好地支持算子的统一管理和分发。

基于vLLM-plugin-flagos, 在100%使用FlagOS替换所有CUDA依赖后, 在英伟达芯片上, 多种Qwen大模型**逼近甚至超过CUDA原生性能**。

模型名称	FlagOS vs. CUDA
Qwen2.5-7B-Instruct	95%
Qwen3_30A_A3B	92%
Qwen3-next	95%~99.5%

众智FlagOS X Qwen3.5

基于vLLM-plugin-flagos, 实现Qwen3.5-397B多模态MoE大模型的多芯片版本适配和发布


- 沐曦、平头哥、天数、华为昇腾、英伟达

众智FlagOS X 面壁MiniCPM-o 4.5

面壁发布的最新全双工大模型在FlagOS的支持下, 迅速适配到六款不同的AI芯片上: 英伟达、华为昇腾、平头哥真武、沐曦、海光、天数


厂商	生态	FlagOS性能相比自家原生
Nvidia	flagos	106.10%
Hygon	flagos	104.57%
Ascend	flagos	104.75%
Iluvatar	flagos	105.22%
Metax	flagos	167.10%
ZhenWu	flagos	146.70%

FlagOS-Robo: 面向具身智能、支持多种芯片的训推一体化工具链




基于FlagOS-Robo, 首次完成在国产千卡集群 (摩尔线程) 上训练具身大脑模型 (RoboBrain2.5)

开源仓库地址: <https://github.com/flagos-ai/FlagOS-Robo>



Loss与CUDA相对误差为0.62%, 训练趋势一致



1024卡相比于64卡扩展效率为90.2%, 接近线性

	RoboBrain-2.5 (8B) Moore Threads	RoboBrain-2.5 (8B) NVIDIA
CV-Bench	94.58	93.32
Where2Place	65	64
CrossPoint	75.4	77.6
RoboSpatial	73.03	75.06
EmbSpatial	75.58	74.84
Real-Bench	90.29	90.74
Sim-Bench	98.78	98.31
Human-Bench	82.07	82.15
Q-Spatial	73.53	74.66
TraceSpatial	83 / 63 / 44	78 / 63 / 32

多个评测集与CUDA对齐

第三部分

双向赋能

FlagOS × OpenClaw的共生演进



FlagOS → OpenClaw

让智能体拥有普惠的推理能力



OpenClaw → FlagOS

智能体成为生态的新入口

OpenClaw对推理算力的极致要求：

- 多步推理：一次任务=5-20次推理调用
- 24×7常驻：永远在线的业务执行
- 高并发低时延：企业级SLA要求


FlagOS提供的“普惠推理能力”：

- 跨芯片统一部署：可以为OpenClaw智能体自由选择最优性价比芯片
- vLLM-plugin-FL：统一了多款AI芯片的模型推理支持

腾讯云上线基于云上国产AI芯片的
FlagOS镜像，内置国产大模型
+OpenClaw



KernelGen v1.0 是一个面向高性能 Triton 算子生成的自动化平台，从“只会写代码助手”升级为覆盖算子生成、基线构建、验证测试与多芯片适配的完整生命周期系统，实现一次描述、自动生成、自动评测、多芯片自动适配。



- 大大提升算子开发效率：200+算子开发从2年缩短到3小时
- 在FlagOS技术栈的支持下，实现了多种AI芯片的算子生成：

	Nvidia	华为	海光	天数	摩尔
成功率(pass5)	70%	60.9%	63.6%	66.4%	68.2%

KernelGen在英伟达上超过ClaudeCode的算子生成性能 (在KernelGen-bench上测试110个算子)

指标	ClaudeCode	KernelGen V2.0 alpha
生成正确性	48.2%	99%
中位数加速比	1.0001	1.0625
加速比>0.8	83%	97.25%
加速比>1	52.8%	90.83%
加速比>1.5	3.8%	18.35%



全面升级，更高的算子生成率、更高加速比、更多芯片；并全面提供web平台版、MCP版、Skills版

基于智能体打造：FlagRelease 开源大模型跨芯自动迁移和版本发布


源源不断自动产生多
芯片的开源大模型

自动化迁移开源大模型至不同AI芯片的工具，并自动发布。通过FlagOS和智能体的相互支持，迁移和发布效率提升4倍，加速模型在多架构环境下的落地效率与生态成熟度。

下载：基于CUDA的原始模型

ModelScope & Hugging Face
& 阿里云 & 腾讯云 & 焕新平台

发布：迁移后的模型、代码及适配不同芯片的Docker 文件



开源模型

GLM4.5系列
Qwen2&3系列
Kimi-K2、phi-4、
grok-2、step3
MiniMax-M1-80k
MiniCPM-v4
Seed-OSS-36B
gpt-oss-120b
ERNIE-4.5-300B-A47B-PT
RoboBrain2.0-7B/32B
MiniCPM-o-2_6-8B

芯片

Nvidia系列
Huawei
ARM
Metax
Iluvatar
Hygon
Cambricon
Kunlunxin
Pingtougge-Zhenwu

一站式提供最新模型、多种芯片的统一版本，用户开箱即用，三步即可完成安装



Deepseek-R1

FlagOS Skills 即将发布：10+种Skills覆盖模型适配、算子生成、性能调优等国产AI芯片的使用场景

<https://github.com/flagos-ai/skills/tree/main/skills/model-migrate-flagos>

model-migrate-flagos: vLLM Model Migration Skill

[中文版](#)

Overview

`model-migrate-flagos` is an AI coding skill that migrates model code from the latest vLLM upstream into the `vllm-plugin-FL` project (pinned at vLLM v0.13.0).

Problem Statement

vLLM upstream iterates rapidly with new models added frequently. However, `vllm-plugin-FL` is pinned at v0.13.0 — directly copying upstream code won't work due to API incompatibilities, missing config classes, broken relative imports, etc. Manual adaptation is time-consuming and error-prone.

This skill automates the entire migration workflow: `copy from upstream` -> `adapt for 0.13.0` -> `register model` -> `verify correctness`, spanning 13 steps with a final token-level accuracy comparison against the upstream server.

Usage

```
# Invoke in your AI coding assistant
/model-migrate-flagos qwen3_5
/model-migrate-flagos kimi_k25
/model-migrate-flagos glm5 /path/to/upstream /path/to/plugin
```

vLLM 上游版本迭代快，新模型不断加入。但 `vllm-plugin-FL` 锁定在 某一个稳定版本（如 v0.13.0），直接复制上游代码无法运行——API 不兼容、配置类缺失、相对导入失效等。手动适配费时且容易出错。

本技能自动化了整个迁移流程：从上游复制代码 → 适配 0.13.0 → 注册模型 → 验证正确性，全程 13 个步骤，最终与上游服务做 token 级精度对比。

<https://github.com/flagos-ai/skills>

FlagOS skills全景图



第四部分

展望未来，AI计算的下一站



我们的大脑可以使用少得多的功耗、训练数据，获得相当的智力水平

	Human Brain		AI Chip
Brain computation	Human brain: ~100 trillion synapses	50 x	GPT-4: 1.8T parameters
Memory	0.5 Petabytes	100 x	1–10 Terabytes per node
Power consumption	0.2watt per trillion synapses	0.000002 x	10k watt per trillion parameters
Training data volume	Single human: 4GB	0.0004 x	Knowledge data: >10 terabytes

无论是AI芯片的架构创新、AI的算法突破，依然远未收敛

单芯片算力扩张（GPU/DSA时代）

代表形态：GPGPU（Tensor Core/矩阵单元）+ DSA（TPU/NPU/ASIC推理卡等），以矩阵乘为中心的“张量化计算”。

解决计算效率问题

物理重构 —— Chiplet + 3D + 近存计算

•代表形态：Chiplet，3D堆叠，HBM及变种（HBF），Near-Memory，存算一体（PIM）

解决数据访问效率问题

阶段二

阶段四

阶段一

系统级Scale-up —— 超节点时代

阶段三

负载驱动的计算形态解耦

代表形态：把“多个GPU/加速器”通过高速互联视为一个逻辑算力单元。

解决互联效率问题

代表形态：

- 量子-智算融合
- 具身跨芯协同、端云协同
- 推理阶段拆分计算（PD分离）、agent专用架构

解决负载差异带来的系统效率问题

面对模型、业务的百花齐放，芯片的多元发展，我们希望

场景1：新模型可在任意芯片运行

新的模型发布，用户可以直接下载到任意的AI硬件上，快速部署使用

场景2：一套代码多芯训练推理

企业内部可能有多种AI芯片服务器，AI团队可以只需开发“一套代码，多芯训练、多芯推理”。

场景3：企业自由选择算力

打破“算法模型绑定算力”的约束，云服务商可以更大范围满足客户需求，企业用户也可以自由选择AI算力。

场景4：混合异构AI云

企业内部的AI算力和公有云上租用的多种异构AI算力可以形成“真正统一”的混合异构AI云，算法开发统一、版本管理统一、训练部署统一、资源调度统一的能力。

我们期待的是AI算力的“普适”，从而带来AI的“普惠”

FlagOS + vLLM + 智能体系统 (OpenClaw) :

开源共建下一代普适、普惠的AI计算基础设施

FlagOS系统技术栈生态：16家厂商25款芯片、65家生态伙伴、16万+下载、658位贡献者