

aibrix 在生产环境提升推理效率的两点实践

谭健楠 火山引擎异构组资深工程师



Content

目录

01 aibrix 介绍

02 部署感知分桶路由

03 multilora



Part 01


aibrix 介绍



aibrix 总览 充分融合 k8s+vllm 社区

Additional features

- Unified AI Runtime with GPU Streaming Loader
- Hybrid Orchestration
- Accelerator Diagnostic and Failure Mockup Tools
- Benchmark tools



Part 02


部署感知分桶路由



负载感知分桶路由

场景：


1. 线上输入方差极大，主要是短输入，少量长输入，可以达到 100k
2. 引擎不同部署单元对不同长度十分敏感
3. 降本与提升性能
4. 用长输入部署抗所有情况



负载感知分桶路由

流程：

1. stormservice operator 给 pod 标记部署信息，比如各实例处理的 min/max prompt 长度
2. router 监听每个实例的分桶配置
3. router 根据分桶配置，各实例负载情况，prompt 长度，动态路由
4. router 支持 pod 分离与 pod 共置的分桶路由
5. 避免长部署实例只处理少量长 prompt，router 会根据负载情况，动态路由部分短序列到长部署实例



负载感知分桶路由



模型	卡型	数据集分布	实验选型的原因
qwen3-14b	A30	根据客户线上情况 mock 了 10000 条数据，方差较大，主要是短输入，少量长输入，可以达到 100k	1. 线上生产环境小模型 + 低端卡居多 2.mock 不同部署的差异性 3.tp2 比 tp4 更有性价比，但没有分桶功能则必须使用 tp4 抗所有长度

baseline :
2*tp4

分桶后 :
2*tp2+1*tp4

长度	是否可以路由到 tp2	是否可以路由到 tp4
0-2500	是	否
2500-5000	是	是
5000+	否	是

最终结论：该实验配置下，相同资源，相似 slo 下，吞吐提升 20%



Part 03


multilora



multi-lora

场景：

1. 端侧设备，延时敏感
2. lora 微调模型
3. 极致降本
4. qps 分布稀疏 2-3



动态加载 adapter & 按请求切换

multi-lora

QPS	input	TTFT			TPOT		吞吐	
		不合并 batch	合并 batch2 与独立部署对比	合并部署 3 与独立部署对比	合并 batch2 与独立部署对比	合并部署 3 与独立部署对比	合并 batch2 与独立部署对比	合并部署 3 与独立部署对比
1	3000	延迟劣化 10 倍 +	10%	12%	16%	21%	14%	17%
	6000		8%	9%	16%	23%	14%	19%
2	3000		10%	13%	12%	20%	10%	17%
	6000		9%	13%	14%	25%	12%	20%
	9000		9%	10%	16%	30%	14%	23%
3	3000		11%	15%	14%	21%	12%	17%
	6000		11%	21%	17%	26%	14%	20%
	9000		10%	21%	20%	38%	16%	29%

引擎层配置：

1. 尽量把流量互补的 adapter 亲和部署
2. 开启合并 batch --max_loras
3. 尽量防止 adapter offload
4. 单卡 adapter 数量不要太多 2-3 个

最终结论：

slo 在影响 10%-25% 的情况下，部署量下降 50%-75%。



Thanks.

AlBrix Slack: [#aibrix](#) v0.6.0 已发布
AlBrix Doc: <https://aibrix.readthedocs.io/latest/>

