

移动业务向数智转型

万卡的 Serverless 调度实践

柴 壮 赵 宇 聪

中国移动数智能化部

2025/11/15





柴壮

中国移动数智能化部架构师



赵宇聪

中国移动数智能化部开发工程师

CONTENT


目录

- 01 为什么选择Serverless架构
- 02 从传统到Serverless：应用演进之路
- 03 Serverless落地案例与业务价值
- 04 通智一体算力资源调度优化

大模型时代新基建


云数智一体化是发展趋势

传统智算中心建设模式



■ 建设模式：烟囱式独立建设及运维，整体成本高

大模型时代智算中心建设模式



■ 建设模式：平台式统一建设及运维，整体成本低

Serverless 架构理念

从资源管理到能力即服务 (AI时代新范式)

能力即服务 (Service as a Capability)



弹性按需 (Elastic On-Demand)

The screenshot shows a '资源配置' (Resource Configuration) interface for '扩容申请' (Scaling Request). It includes a '资源信息' (Resource Information) section with a '自定义资源' (Custom Resource) tab. The configuration details are as follows:

Category	Resource Type	Value
计算资源 (Compute Resources)	训练资源显卡 (Training Resource GPU)	4
	CPU核 (CPU Cores)	1721
	内存 (Memory)	5550
存储资源 (Storage Resources)	训练存储 (Training Storage)	100
	推理存储 (Inference Storage)	10000

按量付费 (Pay-as-you-go)



CONTENT

目录

01 为什么选择Serverless架构


02 从传统到Serverless应用演进之路

03 Serverless落地案例与业务价值

04 通智一体算力资源调度优化

以Serverless 驱动智能应用重构

从传统架构到 Agentic AI 的演进之路



CONTENT

目录

- 01 为什么选择Serverless架构
- 02 从传统到Serverless：应用演进之路
- 03 Serverless落地案例与业务价值
- 04 通智一体算力资源调度优化


基于 Serverless 的 AI 能力全生命周期管理

超大规模
算力集群
管理

多种算力
按实际使
用付费

虚拟化与
弹性伸缩
能力

基于事件
触发业务
请求



模型训练：标准化流程

TensorFlow dmlc mxnet Caffe PYTORCH



AI模型/数据



研发环境



测试环境



生产环境

能力部署：一键服务发布

镜像管理

配置中心

部署流程



AI引擎镜像

业务A

业务B

业务C

...

API网关：统一外部接口

API管理

弹性扩容

服务监控



AI能力


模型研发

部署上线

推理预测

实现业务快速部署和弹性伸缩

面向业务提供强大的AI生产算力与服务保障



云端多节训练



边缘推理



AI预测、实时计算、设备就近接入、近场业务支撑

CONTENT

目录

- 01 为什么选择Serverless架构
- 02 从传统到Serverless：应用演进之路
- 03 Serverless落地案例与业务价值
- 04 通智一体算力资源调度优化

通智一体算力资源调度优化

MaaS

大模型训练推理平台/人工智能开发训练平台



异构资源管理与优化

丰富的GPU、NPU容器化异构资源定义，
完成国产化适配完善的资源监控，资源可视化

容器调度增强

丰富资源调度策略，支持拓扑感知、Gang、共享调度动态
感知资源负载，优化调度决策
相比k8s原生调度速度提升3-5倍

数据加速

支持多种分布式缓存引擎
镜像、数据集内存、硬盘多层缓存加速，提升训推效率

AI任务管理


支持批流AI任务调度，提供工程化工具
提供Paged Attention、并行解码、模型压缩等推理加速支持
支持自动化工作流，完成模型到不同卡转换部署

通智
算一
体算
力资
源调
度优
化

容器
服务

IaaS

算力调度入口



GPU 虚拟化新范式：从资源独占到按需共享

丰富的虚拟化切分能力




多维度虚拟化技术实现


用户态隔离	egpu: 支持用户态按照比例、大小分配显存；依赖少易升级
内核态隔离	cgpu: 支持显存按 MB级 划分，算力支持最小 1% 粒度 的划分，隔离性好
硬件切分	支持 NVIDIA MIG及 国产GPU切分，最小 1/16
vGPU	支持显存按照固定切分供虚拟机使用；算力分时调度
直通	支持物理机中GPU直接分配虚拟机使用
推理场景 GPU利用率最大提升 100% 以上	

N卡和华为、海光、寒武纪、昆仑芯等国产GPU


虚拟机GPU整卡直通 容器可共享



虚拟机GPU卡切分 容器可共享



裸金属GPU容器独占 容器可共享



裸金属GPU卡切分 容器可共享

