

极简智算解决方案落地

Kubernetes & OpenStack & AI

吴文相

Algoblu 首席架构师

2025/11/09





吴文相

Algoblu 首席架构师

聚焦云计算、MEC 边缘计算、容器云、智算 AI 解决方案。是 OpenStack Skyline PTL，CNCF KubeClipper PTL。

CONTENT

目录

- 01 痛点切入和方案目标
- 02 极简架构的底层逻辑
- 03 关键技术支撑
- 04 落地实践案例

1.1 痛点分析

1. 资源浪费

- a. 非核心服务抢占 40%+ 资源 (Ceph)
- b. 运维复杂度提升 60% (工作流等非核心模块)
- c. GPU 利用率 $\leq 55\%$
- d. AI任务响应延迟超 30%

2. 安全缺失

- a. 涉密算力资源与非涉密算力资源未隔离
- b. 管理员账号滥用
- c. 安全审计不完善
- d. 权限管理 RBAC 过于粗放
- e. 对内和对外均缺乏入侵防御设计

1.2 核心价值

核心价值：极简安全降本



架构极简
服务15+→4



适配灵活
双方案/透传/即插



安全可控
三层加密，损耗<5%



落地高效
10h部署，运维-70%



成本最优
单位算力成本-45%

1.3 极简智算平台：资源直达 & 安全无虞

1. 聚焦核心能力

- a. 以“裸机/虚拟机/容器云集群/大模型即服务”为核心
- b. 剥离其它冗余插件：Ceph / 非核心模块 / Neutron 简化

2. 保障安全可控

- a. RBAC & ABAC 的权限设计
- b. 根账号的分段存储，限制终端使用
- c. 涉密算力隔离
- d. 安全策略和安全等级管理
- e. 安全审计强化

3. 简化管理链路

- a. 中心统一管控业务
- b. 边缘极致轻量化

2.1 边缘极简架构

1. 裸机管理

- a. 对接 IroniC (Redfish 适配)
- b. 对接非 IroniC
- c. 对接物理资源管理

2. 虚拟机管理

- a. GPU 透传
- b. RoCE 网络的虚拟化适配

3. 容器云管理

- a. Magnum & KubeClipper & Ubuntu 24.04
- b. 基于 VM & 基于 BM

4. 大模型即服务

2.2 中心极简架构

1. 区域和硬件管理

- a. 统一的硬件资源管理：虚拟化集群/裸机集群/其它设备
- b. 区域接入中心和自发现

2. 资源信息缓存和更新触发

- a. 边沿触发缓存更新
- b. 水平触发缓存更新

3. 业务层

- a. 产品资源和产品
- b. 订单 / 账单 / 计费

4. 辅助服务

- a. 监控和日志
- b. 通知和工单

3.1 关键技术： OpenStack 服务裁剪

1. 以“是否支撑算力供给”为唯一标准
 - a. 仅保留 Nova 和 Glance
 - b. ironic / Heat / Magnum 可选
 - c. Neutron 和 Cinder 简化
2. 适配硬件
 - a. 监控硬件： Redfish/传感器
 - b. 网络硬件： RoCE 交换机
 - c. 存储硬件： 三方文件存储服务
 - d. 计算硬件： GPU PCIe vs NVL C2C
 - e. 异构算力支持（ARM & x86， 国产 GPU 卡等）

3.2 关键技术：中心-边缘协同

1. 中心-边缘“租户”协同

- a. 业务逻辑保留在中心
- b. 租户管理从中心向边缘单向同步

2. 中心-边缘算力协同

- a. 中心订单-边缘算力交付
- b. 边缘算力状态监控和用量统计-中心缓存

3.3 关键技术：GPU精细化管理

1. 资源隔离
 - a. GPU 分片
2. 健康监控
 - a. 实时检测，异常自动迁移
 - b. 用量统计
3. 调度优化
 - a. 区分优先级
 - b. 动态调度
4. GPU透传
 - a. PCIe
 - b. C2C

3.4 关键技术：大模型即服务

1. 提供 Web 与 API 双通道
2. 5 分钟内完成上线
 - a. 模型选择
 - b. GPU 规格
 - c. 加密策略配置并生成 K8S Deployment
 - d. 镜像统一托管
 - e. 版本可回溯
 - f. 部署过程零人工干预

3.5 关键技术：监计一体

1. 监控指标源可配置
2. 实时流处理计费
3. “加密通道、密钥、损耗”同步可视化
4. 运维-财务-合规三端同源可信

4.1 性能对比

极简全面领先



4.2 成本效益

1. 硬件投入减少 20% (取消冗余服务器)
2. 年省人力成本 30 万+ (运维工作量 -70%)
3. 单位算力成本 降低 45%
4. 节省安全成本 50 万+ (无需独立加密设备)
5. 支持外接三方入侵防御服务

4.3 稳定合规

90天零故障



稳定性

连续运行90天，核心服务可用性 99.95%，
加密通道零中断。



合规性

审计日志满足等保三级，加密方案符合数
据安全法。



准确性

计量数据与财务对账误差 $<0.1\%$ ，一次性通
过第三方检测。

Q&A

THANKS

