

使用GPU切片和虚拟化技术优化AI工作负载

李孟轩

密瓜智能研发工程师

2025/10/29

李鹏

蔚来云端工程部训练

加速负责人

2025/10/29





李孟轩

密瓜智能研发工程师

HAMi Maintainer

Volcano Approver



李鹏

蔚来云端工程部

训练加速负责人

CONTENT

目录


- 01 第一章：GPU算力集群现状
- 02 第二章：异构集群的设备复用方案
- 03 第三章：蔚来技术团队的实践

第一章：GPU算力集群现状

异构算力集群是未来推理集群的趋势

In-house accelerators gaining momentum across the board, while GPU shipments still grow 60% over 4 years

Global Datacenter AI chip shipments¹ (m) and implied 2027 revenues (\$bn)




Source: Corporate reports, Mercury Research and NSR estimates and analysis.

NewStreet
Research

Pierre Ferragu | Global Technology Research | GlobalTech@newstreetresearch.com | 4 January 2024

IDC

中国加速计算服务器市场预测，2024-2028




来源：IDC中国，2024


- 异构算力的发展迅猛，目前未见收敛迹象
 - 集群管理是收敛的
- 集群中异构算力管理会是一个长期的课题

第一章：GPU算力集群现状


异构算力集群的痛点：利用率不足



企业 GPU 真实使用率情况



Source: TIRIAS Research



51-70%
小于50%
86-100%
71-85%


- 异构算力的规格越出越大
- 但是小模型依然有很大的场景

➤ 利用率成为普遍痛点

Copyright © 2024 by ClearML. All rights reserved


第一章：GPU算力集群现状

异构算力集群的痛点：难以统一管理



升腾910系列互联拓扑

- 每个卡都有自己的拓扑亲和性
- 每个设备厂商都有配套的优化调度组件
- 互相之间的调度优化组件很可能无法兼容
- 每个设备需要一个独立的集群来维护



沐曦互联拓扑


第二章：异构集群的设备复用方案

device-plugin 的多资源名上报




AWS神经网络芯片：1个设备包含 2 个核组

- 通过设备插件上报不同的资源名进行虚拟化管理
- 不同厂商的实现方式不同
- 只支持单卡虚拟化



第二章：异构集群的设备复用方案

DRA: Dynamic Resource Allocation



灵活的设备过滤：使用通用表达式语言（CEL）对特定设备属性进行细粒度过滤。


设备共享：多个容器或 Pod 可通过引用对应的资源声明共享同一资源。

集中式设备分类：设备驱动程序和集群管理员可以使用设备类（device class）为应用操作者提供针对不同用例优化的硬件类别

细化Pod请求：使用 DRA 时，应用操作者无需在 Pod 资源请求中指定设备数量。相反，Pod 引用资源声明，该声明中的设备配置会应用到 Pod。

第二章：异构集群的管理方案


DRA: Dynamic Resource Allocation



基于筛选式的设备复用：
DRA Driver可以上报若干个DeviceClass，可供ResourceClaim或ResourceClaimTemplate选择，但是其可选择的范围不能超过DeviceClass所提供的内容，所以自由度欠缺

第二章：异构集群的设备复用方案

HAMi: Heterogeneous AI computing middleware




HAMi通过调度器扩展以及容器内的符号劫持来实现GPU虚拟化

需求:

- Nvidia driver version ≥ 440
- CUDA version ≥ 10.2

特性:

- 显存隔离
- 算力隔离
- 错误限制
- 无侵入



第二章：异构集群的设备复用方案

HAMi的使用方式

resources:

limits:

nvidia.com/gpu:

nvidia.com/gpumem: 10240


nvidia.com/gpucore: 30

- nvidia.com/gpu: 容器中可见的GPU数量
- nvidia.com/gpumem: 每个GPU可使用的显存大小, 若不填则为使用整卡
- nvidia.com/gpucore: 每张卡使用的算力百分比

```
root@gpu-demo-6b6b88b75b-x9tjb:~# nvidia-smi
[HAMi-core Msg(35:140111864956736:libvgpu.c:836)]: Initializing....
Thu Apr 18 06:22:54 2024
```

NVIDIA-SMI 535.104.12 Driver Version: 535.104.12 CUDA Version: 12.2									
GPU	Name	Perf	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr.	ECC	
Fan	Temp		Pwr:Usage/Cap	Memory-Usage	Memory-Usage	GPU-Util	Compute M.	MIG M.	
0	NVIDIA A800 80GB PCIe	P0	On	00000000:13:00.0	Off	0%	Default	0	
N/A	36C		81W / 300W	0MiB / 10240MiB			Disabled		
1	NVIDIA A800 80GB PCIe	P0	On	00000000:1C:00.0	Off	0%	Default	0	
N/A	39C		82W / 300W	0MiB / 10240MiB			Disabled		

```
Processes:
GPU  GI  CI  PID  Type  Process name  GPU Memory
ID   ID   ID                      Usage
-----
[HAMi-core Msg(35:140111864956736:multiprocess_memory_limit.c:434)]: Calling exit handler 35
root@gpu-demo-6b6b88b75b-x9tjb:~#
```



第二章：异构集群的设备复用方案

Volcano vGPU




resources:

limits:

`volcano.sh/vgpu: 1`

`volcano.sh/vgpu-memory: 10240`



第二章：异构集群的管理方案

HAMi vgpu用户



第二章：异构集群的管理方案

HAMi 2.7——2.8新特性

v2.7新特性（已经支持）：

主要特性：

- 显存/算力资源配额
- NVIDIA 拓扑感知

新增设备复用支持：

- AWS神经网络芯片
- 昆仑芯

v2.8新特性（正在进行，预计12月或1月发布）：

主要特性：

- 提升大规模集群稳定性
- WebUI增加异构设备


新增设备复用支持：

- 阿里PPU
- AMD Mi300x
- CloudMatrix



第三章：蔚来技术团队的实践

蔚来云端集群vGPU方案



第三章：蔚来技术团队的实践


vgpu性能评测

Vgpu性能评测：

借鉴hami的思路
但方向转向对ai任务的性能优化提供辅助

优点：
无侵入，不需要import 包，无需改代码

可实时分析



感谢大家参加我们的session


- Github

<https://github.com/Project-HAMi/HAMi>

- Website

<http://project-hami.io/>

- HAMi用户微信群可以通过添加右图小助手加入



进群小助手



feedback