

超越网关

基于 Gateway API Inference Extension 的
推理流量控制实践

丁飞 邱沐阳

蚂蚁集团数字科技

2025-11-15



丁 飞

蚂蚁集团数字科技

“算力云”训推一体平台
负责人



AI Infra、PaaS、服务网格、中间件、内存数据库

邱沐阳

蚂蚁集团数字科技

“算力云”训推一体平台
研发工程师



AI Infra、PaaS

让金融 AI 创新从构想到落地的
"最后一公里"触手可及





CONTENT

目录


- 01 推理服务网关：机遇与挑战
- 02 Gateway API Inference Extension：
从定义到落地
- 03 成果、局限与愿景
- 04 QA

01 推理服务网关：机遇与挑战

推理服务网关：机遇与挑战

From API GW to LLM GW

业务发展
能力复用
生产稳定
适配灵活
方案统一




推理服务网关：机遇与挑战

From API GW to LLM GW

业务发展
能力复用
生产稳定

适配灵活
方案统一



Gateway API
Inference Extension

02 Gateway API Inference Extension: 从定义到落地

02 定义

Gateway API Inference Extension : 从定义到落地

什么是 Gateway API Inference Extension (GIE)

“

Gateway API Inference Extension 是对标准 *Gateway API* 的一组增强扩展, 旨在将现代 AI 推理工作负载的特性深度融入服务网关的流量管理能力中。


它引入了面向大模型服务的关键语义支持, 并利用 **Envoy** 的外部处理机制 (*External Processing*), 使得任何同时支持 **ext-proc** 和 **Gateway API** 的网关, 均可被扩展为具备推理

”

感知能力的推理网关


Gateway API Inference Extension : 从定义到落地

什么是 Gateway API Inference Extension (GIE)



Gateway API Inference Extension : 从定义到落地

a) 定义: InferencePool & InferenceObjective



1. InferencePool


- a) 在哪选: 框定Pod选择范围
- b) 谁来选: 指定端点选择器

2. InferenceObjective (opt.)

- a) 怎么选: 约定服务目标

Gateway API Inference Extension : 从定义到落地

b) 实现: EndPointPicker




一个 **可扩展的** 研发框架

一组 **开箱即用的** 能力插件

得到 推理服务流量控制 **能力增强**

Gateway API Inference Extension : 从定义到落地

Eg. Request flow (by llm-d)



02 落地



Gateway API Inference Extension : 从定义到落地

挑战

服务发现

网关适配

EPP扩展

EPP生命周
期管理

Gateway API Inference Extension : 从定义到落地

挑战




如何替换以微服务框架/Service Mesh为核心的服务发现机制，并完成对各类网关的服务注册

云原生

插件机制


Gateway API Inference Extension : 从定义到落地

服务发现



Gateway API Inference Extension : 从定义到落地

服务发现



Higress



Kong



envoy

Model
Deployment

RoleBased
Group

Service

InferencePool

Gateway API Inference Extension : 从定义到落地

挑战



如何适配支持 GIE 程度各异的多种网关，实现能力平权？

Gateway API Inference Extension : 从定义到落地

挑战

Fully
supported



Partially
supported



插件机制

DO NOT
support



Gateway API Inference Extension : 从定义到落地


网关对接: Higress

现状

- Gateway API 版本过低, GIE 不可用
- 支持基于WASM的插件扩展
 - 不支持gRPC, 即不支持 ext-proc

解法

- 协议转换插件 ext-proc on HTTP
- 自定义路由增强



Gateway API Inference Extension : 从定义到落地


网关对接: Kong

现状

- 不支持 GIE
- 支持基于GO的插件扩展

解法

- ext-proc client 插件
- setTarget 扩展机制



现实

Gateway API Inference Extension : 从定义到落地

挑战




如何解决 业务快速迭代 与 同步社区演进
之间的冲突

分库解耦

架构依赖

Gateway API Inference Extension : 从定义到落地

EPP 扩展




Gateway API Inference Extension : 从定义到落地

EPP 扩展 : a) LoRA Aware

```
1 func (f *LoraAdaptorFilter) Filter(ctx context.Context, _ *types.CycleState, request *types.LLMRequest, pods []types.Pod) []types.Pod {
2     var filteredPods []types.Pod
3
4     for _, pod := range pods {
5         if pod.GetPod().Labels[highwayapi.LabelLoraAdaptorPrefix+targetModel] == "true" {
6             filteredPods = append(filteredPods, pod)
7         }
8     }
9
10    return filteredPods
11 }
```


Gateway API Inference Extension : 从定义到落地

EPP 扩展: b) KVCache Aware



Gateway API Inference Extension : 从定义到落地

挑战



如何部署 EPP 并实现其完整的生命周期管理

研发成本

运维成本


负载风险

灰度能力

资源成本

Gateway API Inference Extension : 从定义到落地

EPP 生命周期管理 a) EPP Role




思路：复用 Workload 多 Role 能力，同时将 EPP 生命周期与模型服务绑定

优势：研发、运维成本几近为0

劣势：生命周期捆绑带来资源浪费、灰度能力极差

Gateway API Inference Extension : 从定义到落地

EPP 生命周期管理 b) 控制器




思路：独立于模型服务，使用云原生控制器机制处理

优势：中庸

劣势：引入新组件带来的成本、灰度问题没有根本上解决

Gateway API Inference Extension : 从定义到落地

EPP 生命周期管理 c) 单例



思路：一套控制器处理集群所有模型

优势：可复用成熟的发布部署平台灰度能力

劣势：负载风险很高、研发压力很大

Gateway API Inference Extension : 从定义到落地

EPP 生命周期管理

部署架构	EPP Role	控制器	集群级单实例
部署关系	EPP: 推理服务 =1:1	EPP: 推理服务 =1:1	EPP: 推理服务 =1:N
研发成本	低	中	高
运维成本	无	中	低
资源成本	高	中	低
负载风险	低	低	高
灰度能力	差	差	优

03 成果、局限与愿景

成果、局限与愿景

成果

标准解决方案

生产落地

系统吞吐量、TTFT 提升

成果、局限与愿景


局限

1. 社区版 **EPP** 离大规模生产可用还有一定距离
 - a) 协议适配滞后
 - b) 某些插件能力并非开箱可用
 - c) 框架设计存在部分不合理

成果、局限与愿景

局限

2. 非GIE原生支持的网关接入存在问题
- a) 适配工作不产生业务价值、无法收敛
 - b) 能力对不齐、技术有风险



成果、局限与愿景

愿景



[NEW]

vLLM Production Stack



[NEW]

HiGress



[NEW]

[NEW]

EPP

[NEW]

Gateway API

Inference Extension

成果、局限与愿景

愿景

更标准、更统一、更灵活的推理流量控制扩展事实标准

04 QA




"iefgnid"[::-1]
中国大陆



扫一扫上面的二维码图案，加我为朋友。



QMY
江苏 南通



扫一扫上面的二维码图案，加我为朋友。