

多模板遇上多集群

基于 Karmada 的 AI 大数据应用的资源治理与智能调度

张壮

华为云研发工程师

2025/11/15





张壮

华为云研发工程师，Karmada社区技术专家

华为云软件工程师，Karmada 社区技术专家，专注于多集群调度、AI 应用部署及 CI/CD 领域，致力于推动云原生项目的落地与生态发展。

CONTENT

目录

- 01 多模版+多集群架构的融合挑战
- 02 Karmada 核心能力演进
- 03 资源治理与智能调度
- 04 实践落地与未来展望

01

多模版+多集群架构的融合挑战



多模版+多集群架构的融合挑战

什么是多模版应用

AI 与大数据应用普遍呈现‘**多模版**’特征：一个任务包含多个异构Pod模板，资源需求差异显著



多组件协同

AI/大数据任务由协调、计算等异构组件构成，需协同运行。



多模板定义

单个应用定义多个Pod模板，如PyTorchJob含主控与工作副本。




资源差异大

各模板资源需求不同，副本数与算力配置差异显著。

多模版+多集群架构的融合挑战

什么是多模版应用



```
# sparkApplication CR
spec:
  driver:
    cores: 1
    memory: "1Gi"
  executor:
    instances: 5
    cores: 2
    memory: "4Gi"
```

```
# flinkDeployment CR
spec:
  taskManager:
    resource:
      cpu: 1
      memory: "1Gi"
  jobManager:
    replicas: 4
    resource:
      cpu: 1
      memory: "1Gi"
```

多模版+多集群架构的融合挑战

为什么需要多集群

HA & 容灾:

多集群部署和故障恢复等能力, 保障业务 SLA

基础设施 & 异构资源利用:

业务扩张, 基础设施往多集群部署演进

满足不同任务需求 (如训练 vs 推理), 智能调度至最适合的硬件环境 (GPU、TPU、CPU), 提升资源利用率。

区域化服务: 计算靠近数据源, 多地分布场景

多模版+多集群架构的融合挑战

新架构下的难题和挑战

如何精准刻画应用整体资源画像？这是精准调度的前提

多模版特征：各模版资源需求各异，副本数不统一

资源复合性：多模版整体的资源需求为多个模版多维度复合计算的结果

API 定义各异：业界各多模版应用的 API 定义各异，难以统一描述

多模版+多集群架构的融合挑战

新架构下的难题和挑战

多集群多租户环境下，如何公平分配资源？

管理边界模糊：跨集群资源使用边界不清，容易引发资源挤兑与服务降级风险

全局视图缺失：传统配额仅支持单集群，难以应对跨集群、多模板应用的复合资源需求场景

02

Karmada 核心能力演进



Karmada 核心能力演进


什么是 Karmada

Karmada: 开放的、多云的、多集群的
Kubernetes 编排



Karmada 是 CNCF 孵化项目，一个开源的 Kubernetes 原生多集群编排平台，无需修改应用，即可实现跨集群的自动调度、高可用部署与统一治理。

项目地址: <https://github.com/karmada-io/karmada>



Karmada 核心能力演进


多集群治理：资源解释器

资源解释器：用于解释常见的 K8s 原生资源以及扩展资源。

通过内置或自定义的解释规则，帮助 Karmada “理解” 工作负载各维度的资源信息，包括：

- 工作负载状态聚合
- 资源请求
- 依赖资源解析等


以支撑 Karmada 的高级调度策略。



Karmada 核心能力演进

多集群治理：资源解释器


内置主流AI/大数据工作负载支持，同时开放API允许用户自定义解释逻辑，满足多样化场景需求



Karmada 核心能力演进

多集群治理：资源解释器

```
# sparkApplication CR
spec:
  driver:
    cores: 1
    memory: "1Gi"
  executor:
    instances: 5
    cores: 2
    memory: "4Gi"
```




```
# resourceBinding
spec:
  components:
    - name: driver
      replicaRequirements:
        resourceRequest:
          cpu: 1
          memory: "1Gi"
      replicas: 1
    - name: executor
      resourceRequest:
        cpu: 2
        memory: "4Gi"
      replicas: 5
```

以 SparkApplication 为例，Karmada 借助资源解释器，从 SparkApplication 中完整、无损地提取资源画像（包括副本数、资源请求、亲和性、GPU 需求等），为跨集群调度提供精准依据。

Karmada 核心能力演进

多集群治理：联邦资源配额



控制面级别的配额管理 FederatedResourceQuota

跨集群的集中配额检查：

- ❑ 针对 Karmada 控制平面的资源创建和更新
- ❑ 通过拒绝会超过命名空间总配额的调度请求来防止过度调度。

Karmada 核心能力演进

多集群治理：联邦资源配额



统一配额视图

在控制平面提供租户级全局
配额统一视图与管理入口。



租户公平隔离

通过命名空间划分，保障多团
队间资源隔离与公平共享



多模版支持

基于资源解释器提供的精确资源画像，
实现多模板工作负载的精确资源计量。

联邦配额管理（Federated Resource Quota） 基于资源解释器提供的精确资源画像，在控制平面实现跨集群统一配额控制

Karmada 核心能力演进

多集群治理：联邦资源配额

```
# sparkApplication CR
spec:
  driver:
    cores: 1
    memory: "1Gi"
  executor:
    instances: 5
    cores: 2
    memory: "4Gi"
```

```
# FederatedQuota
status:
  overall:
    cpu: "10"
  overallUsed:
    cpu: "2"
```


以该配置为例：成员集群剩余 Quota 为 8 个 CPU，而 SparkApplication 的资源需求为 11 个 CPU。由于剩余配额不足，调度器将拒绝将其调度至成员集群。

Karmada 核心能力演进

多集群治理：调度预估


Karmada 提供了调度精准预估插件，确保业务被调度到资源充足的集群，并尽量均衡各集群的资源利用率。

- 可拔插
- 独立服务运行
- grpc 通信
- 综合决策机制



Karmada 核心能力演进

基于 Quota 的调度预估



多租户挑战

在多租户环境中，不同团队共享同一成员集群，资源竞争激烈。为防止资源滥用，集群管理员普遍采用 Quota 限制单集群命名空间级别的CPU、内存和存储用量。

跨集群差异化


各成员集群可设置不同的配额策略

配额感知调度

Karmada 调度器可解析目标集群的 ResourceQuota 配置，计算多模板在配额约束下的最大可部署 Set 数，避免因超限导致部署失败。

Karmada 核心能力演进

基于节点级可用资源的调度预估



动态评估

支持实时感知节点资源变化，确保调度决策符合实际运行环境需求。

细粒度

传统调度依赖集群总资源，忽视节点间分布不均，易导致虽总量充足但无法容纳新Pod的调度失败问题，影响应用部署效率。

多维度

依据节点资源，结合节点亲和性、污点等约束，多维度评估

03

资源治理与智能调度




资源治理与智能调度

多模版调度

两层调度：

第一层调度：由 Karmada Scheduler 完成，决定工作负载分发到哪些成员集群。调度对象是**高级工作负载**


第二层调度：由各集群的 Kube-scheduler 完成，负责将 Pod 绑定到具体节点。调度对象是 **Pod**



资源治理与智能调度

多模版调度

场景：将多模版工作负载调度到某个有充足资源的成员集群



资源治理与智能调度

多模版调度

```
# PropagationPolicy
spec:
  resourceSelectors:
    - apiVersion: batch.volcano.sh/v1alpha1
      kind: Job
      name: dk-job
  placement:
    clusterAffinity:
      clusterNames:
        - member1
        - member2
  replicaScheduling:
    replicaDivisionPreference: Aggregated
    replicaSchedulingType: Divided
  spreadConstraints:
    - spreadByField: cluster
      minGroups: 1
      maxGroups: 1
```

匹配的多模版为: VolcanoJob dk-job

期望集群: member1 和 member2

限制最终的目标集群为 1 个

04

实践落地与未来展望



实践落地

KubeCon North America:

- Bloomberg's Journey to Manage a Multi-Cluster Training Application with Karmada
- Bloomberg's Journey to Improve Resource Utilization in a Multi-Cluster Platform

KubeCon China:


- How Bloomberg Creates a Resilient Data Analytics Platform Using Karmada

重点使用特性:

- 资源解释器
- 联邦配额
- 多模版调度
- 跟随分发
- 故障恢复

未来展望

部署形式：一对一 vs 一对多



1 个多模版部署到1个集群，
还是拆分到多个集群？

如果拆分到多个集群，如何
拆分？拆分粒度是什么？

THANKS

