


Higress 在 AI 与 MCP 网关场景下的探索与实践

程治玮

NVIDIA 高级工程师, Higress Maintainer

2025/11/15





程治玮

嘉宾职位：NVIDIA 高级工程师，Higress Maintainer

个人简介： 开源爱好者，专注云原生、AI Infra 与 Elastic Stack 技术生态

CONTENT

目录

01 AI 网关简介

02 Higress AI 网关核心功能介绍


03 Higress MCP 实践与应用

04 Demo

01 AI 网关简介

网关演进形态概览

伴随软件架构的演进网关形态也在持续进化，K8S 成为统一运维界面，AI 成为流量增长的核心驱动力



AI 网关的应用场景


1. **模型服务提供商 (MaaS) 的接入层**: 部署在模型推理服务之前, 通过智能的负载均衡策略将请求转发给后端最合适的计算资源
2. **AI 应用的开发网关**: 屏蔽不同厂商 API 的协议差异, 提供一个统一的调用接口
3. **企业内部的中央 AI 网关**: 统一的安全管控、成本审计与分摊
4. **MCP 工具生态的统一入口**: 集中管理 MCP 工具的调用请求、REST API 与 MCP 的协议转换

02 Higress AI 网关核心功能介绍

Higress AI 网关核心功能




模型切换



模型切换的核心价值

- **业务需求适配:** 根据业务复杂性或性能要求选择不同模型。
- **数据隐私与合规性:** 在处理敏感数据时, 可能需要切换到符合特定法规的模型, 确保数据处理的安全性。
- **性能优化:** 根据实时性能需求, 可能会切换到更快的模型以减少延迟。
- **成本与性能平衡:** 根据预算动态选择性价比最优的模型
- **领域特定需求:** 针对特定领域 (如法律、医学), 可能需要切换到在相关领域微调过的模型, 以提高推理准确性。


LLM 服务 Fallback



LLM 服务 Fallback 的核心价值

当主 LLM 服务因为各种原因出现异常，不能提供服务时，网关侧可以快速将请求 Fallback 到配置的备选 LLM 服务。这样保证了业务的持续性，争取了排查主 LLM 服务问题的时间。

多 API Key 管理




多 API Key 管理的核心价值

像 ChatGPT, 豆包这类闭源 LLM, 或者百炼这种托管 LLM 平台, 都是以提供 API 的方式供大家使用 LLM 的能力, 但是受限底层 GPU 资源的压力, 以及整体平台的稳定性, 每个用户都有请求 QPS 的最大限制 (基于平台的 API Key 的维度), 且上调比较困难。

- **突破 QPS 上限:** 通过管理闭源 LLM 或 LLM 托管平台的多个 API Key, 变相提升 QPS 上限, 提升业务性能。

基于 Token 维度的限流



基于 Token 维度限流的核心价值


- **成本管理：**LLM 的费用通常基于 Token 数量计算，限流帮助用户避免超支。例如，服务提供商可能按 Token 使用量提供不同定价层。
- **资源管理：**LLM 需要大量计算资源，限流防止系统过载，确保所有用户都能获得稳定性能，尤其在高峰期。
- **用户分层：**可以基于 Consumer Id 或者 API Key 进行 Token 限流。
- **防止恶意使用：**通过限制 Token 数量来减少垃圾请求或攻击。

限流策略

- **判断条件：**
 - 支持按请求 Header 判断。
 - 支持按请求 Query 参数判断。
 - 支持按请求 Cookie 判断。
 - 支持按客户端 IP 判断。
- **限流规则：**
 - 精确匹配。
 - 前缀匹配。
 - 正则匹配。
 - 任意匹配。
- **限流范围：**每秒、每分钟、每小时、每天。

Token 配额管理

ai-quota 插件支持针对不同的 consumer 按分配的配额策略进行限流，同时提供完善的配额管理能力，包括查询、刷新及增减配额操作。



Token 配额管理的核心价值

token 配额管理使企业可以将统一管理/采购的 LLM 服务资源按需精确分配给不同部门或用户，既防止资源浪费，又有效控制预算使用。

内容安全



内容安全的核心价值

- **防止攻击**: 验证输入可以阻止恶意提示注入，防止模型生成有害内容。
- **维护模型完整性**: 避免输入操纵模型，导致错误或偏见输出。
- **用户安全**: 确保输出没有有害或误导性内容，保护用户免受不良影响。
- **内容适度**: 过滤掉不适当的内容，如仇恨言论或不雅语言，特别是在公共应用中。
- **法律合规**: 确保输出符合法律和伦理标准，尤其在医疗或金融领域。

一键开启内容安全防护

← bailian-ds-r1

API详情 策略与插件 使用指南 统计 日志

预置策略与插件

☒ 内容安全防护

* 防护服务

默认填充内容安全的URL，您可以 [参考文档](#)

检查请求 ☒ 开启 ☐ 关闭

检查响应 ☐ 开启 ☒ 关闭 ☒ 检查响应应用于检查大模型的回答内容是否合规，生效时会使流式响应变为非流式

防护等级

保存 取消


结果缓存



结果缓存的核心价值

- **提高效率**: 如果相同的输入反复出现，缓存可以避免重复请求大语言模型，从而加快响应速度，特别是在处理常见问题时。
- **降低成本**: 减少模型调用次数可以节省计算资源，尤其对大型模型来说成本较高。
- **保持一致性**: 缓存确保相同输入产生相同输出，有助于测试和合规性场景。

LLM 可观测




LLM 推理服务可观测

- 大语言模型的 metrics 信息: 输入 token、输出 token、首个 token 的 RT (流式请求)、请求 RT 等指标, 支持在网关、路由、服务、模型四个维度上进行观测。
- 支持在日志、trace 中记录 LLM 请求的输入和输出内容。
- 传统指标: QPS (request per second), RT (延时), 错误率。
- 网关功能指标:
 - 基于consumer 的 token 消耗统计。
 - 基于模型的 token 消耗统计。
 - 限流指标: 每单位时间内有多少次请求因为限流被拦截; 限流消费者统计 (是哪些消费者在被限流)。
 - 缓存命中情况。

LLM 可观测

内置 AI 可观测大盘



LLM 服务负载均衡




LLM 服务负载均衡

- 全局最小请求数负载均衡：借助 Redis 实现了全局最小请求数负载均衡算法，根据每个 LLM 实例上正在处理的请求数进行负载均衡。
- 前缀匹配负载均衡：将请求转发给 KV cache 匹配最长的 LLM 实例，避免重复计算 KV cache，大幅优化请求的吞吐量和延迟。
- GPU 感知负载均衡：根据 LoRA Adapter 亲和、队列长度、KV cache 使用率进行负载均衡。

03 Higress MCP 实践与应用

什么是 MCP

模型上下文协议 (Model Context Protocol) 是一个开源协议，由 Anthropic 公司开发，旨在让 LLM 能够以标准化的方式连接到外部数据源和工具。





Function calling



MCP

基于存量 OpenAPI 构建 MCP Server




基于存量 OpenAPI 构建 MCP Server

可以使用 [openapi-to-mcpserver](#) 工具，实现 OpenAPI 规范到 MCP Server 插件配置的自动转换

○ ○ ○

```
1 go install github.com/higress-group/openapi-to-mcpserver/cmd/openapi-to-mcp@latest
2 openapi-to-mcp --input path/to/openapi.json --output path/to/mcp-server.yaml
```

Nacos MCP Registry



Nacos MCP Registry

使用 Nacos MCP Registry 的优势在于：

- **统一注册与动态发现**：所有 MCP Server（包括存量 API 转换、自研、第三方的）均可以注册到 Nacos 进行统一管理
- **MCP 信息动态下发实时生效**：Nacos 可以动态管理和下发 MCP 信息、Tools 及 Prompt
- **MCP 版本与灰度管理**：Nacos 天然支持配置的历史版本管理和灰度发布。当需要调整 Tool 描述时，可以对比不同版本描述对 AI 调用效果的影响，确保变更平稳、可控，并可在出现问题时快速回滚

Higress 开源 MCP 市场

Higress 开源 MCP 市场地址: <https://mcp.higress.ai>

MCP Marketplace

探索

Higress.ai

如何发布 MCP 到该市场

Github

ZH EN

API 即 MCP，让 AI 连接现实更低成本

借助 Higress，瞬间即可将现有 API 转化为 Remote MCP Server，铺设 AI 与现实世界最短的连接路径

Q 请输入内容

↓ 排序: 按热度

免费试用: 9

时间服务

创建者: Higress Official

时间标定: 可以基于指定的时区提供当前时间。它还可以通过用户的 IP 地址确定用户所在位置，然后基于该位置所在时区提供精确的时间

工具 | 2025.04.16 更新

查看 Higress 配置

IP 查询位置

创建者: Higress Official

空间定位: 基于 IP 定位用户的位置，支持自动获取用户 IP

阿里云市场 | 2025.04.16 更新

查看 Higress 配置

Blockscout

创建者: Community

Blockscout is an open-source blockchain explorer for inspecting and analyzing EVM-compatible blockchains. This MCP server for Blockscout wraps the official Blockscout multi-chain API, exposing blockchain data - balances, tokens, NFTs, contract metadata

工具 | 2025.04.16 更新

查看 Higress 配置

股票助手

创建者: Higress Official

专为股票、期货及外汇市场设计的多功能服务。提供了多种工具，包括K线图、报价、排行等，以帮助用户获取实时和历史数据，进行技术分析和决策支持

阿里云市场 | 2025.04.16 更新

查看 Higress 配置

黄历/假期助手

创建者: Higress Official

支持中国假期/调休信息查询，以及中国传统老黄历（择时）查询

阿里云市场 | 2025.04.16 更新

查看 Higress 配置

WolframAlpha

创建者: Higress Official

使用WolframAlpha LLM API 与LLM交互，获取针对大型语言模型使用而优化的结果

工具 | 2025.04.23 更新

查看 Higress 配置

E2B

创建者: Higress Official

E2B Code Interpreter API 的 MCP 服务器实现，提供可执行Python代码沙盒环境。

代码 | 2025.04.23 更新

查看 Higress 配置

BraveSearch

创建者: Higress Official

BraveSearch 支持联网搜索及本地搜索功能，提供准确的搜索服务

搜索 | 2025.04.16 更新

查看 Higress 配置

Context7

创建者: Higress Official

Context7 直接从源码中提取最新的、特定版本的文档和代码示例，让代码生成、调试获得更准确的答案。

代码 | 2025.04.29 更新

查看 Higress 配置

MCP Servers: 50

时间服务

创建者: Higress Official

时间标定: 可以基于指定的时区提供当前时间。它还可以通过用户的 IP 地址确定用户所在位置，然后基于该位置所在时区提供精确的时间

工具 | 2025.04.16 更新

查看 Higress 配置

IP 查询位置

创建者: Higress Official

空间定位: 基于 IP 定位用户的位置，支持自动获取用户 IP

阿里云市场 | 2025.04.16 更新

查看 Higress 配置

Blockscout

创建者: Community

Blockscout is an open-source blockchain explorer for inspecting and analyzing EVM-compatible blockchains. This MCP server for Blockscout wraps the official Blockscout multi-chain API, exposing blockchain data - balances, tokens, NFTs, contract metadata

工具 | 2025.04.16 更新

查看 Higress 配置

股票助手

创建者: Higress Official

专为股票、期货及外汇市场设计的多功能服务。提供了多种工具，包括K线图、报价、排行等，以帮助用户获取实时和历史数据，进行技术分析和决策支持

今日投资-板块行情

创建者: Community

整合了行业和概念板块的最新实时行情及其成分明细数据，涵盖指数、涨跌幅、成交量、总市值、涨跌幅排名、领涨股等关键市场指标，面向智能投研与市场热点追踪，助力全方位洞察行业与概念板块的最新动态及成分表现

黄历/假期助手

创建者: Higress Official

支持中国假期/调休信息查询，以及中国传统老黄历（择时）查询



Higress 开源 MCP 市场

MCP Marketplace

探索 \ IP 查询位置

Higress.ai

如何发布 MCP 到该市场

Github

ZH EN



IP 查询位置

查看 Higress 配置

创建者: Higress official | 类型: 阿里云市场 | 2025.04.16 更新

空间定位: 基于IP定位用户的位置, 支持自动获取用户IP

概览 工具

ip查询位置

API认证需要的APP Code请在阿里云API市场申请: <https://market.aliyun.com/apimarket/detail/cmapi00054907>

什么是云市场API MCP 服务

阿里云市场是生态伙伴的交易服务平台, 我们致力于与合作伙伴提供覆盖上云、商业化和售卖的全链路服务, 帮助客户高效获取、部署和管理优质生态产品。云市场的API服务涵盖以下几个类目: 应用开发、身份验证与金融、车辆交通与物流、企业服务、短信与运营商、AI应用与OCR、生活服务。云市场API依托Higress提供MCP服务, 您只需在云市场完成订阅并获取AppCode, 通过Higress MCP Server进行配置, 即可无缝集成云市场API服务。

如何在使用云市场API MCP 服务

进入API详情页, 订阅该API, 您可以优先使用免费试用。

前往云市场用户控制台, 使用阿里云账号登录后查看已订阅API服务的AppCode, 并配置到Higress MCP Server的配置中。注意: 在阿里云市场订阅API服务后, 您将获得AppCode。对于您订阅的所有API服务, 此AppCode是相同的, 您只需使用这一个AppCode即可访问所有已订阅的API服务。

云市场用户控制台会实时展示已订阅的预付费API服务的可用额度, 如您免费试用额度已用完, 您可以选择重新订阅。

MCP服务器配置功能简介

功能简介

该服务可以基于用户的IP分析用户所在位置, 可以无需主动提供IP, 支持IP自动获取(基于API网关的能力)。位置信息还可以用于确定用户所在的时区, 从而提供基于用户位置的精确本地时

相关 MCP Servers



时间服务

创建者: Higress Official

时间标准: 可以基于指定的时区提供当前时间, 它还可以通过用户的IP地址确定用户所在位置, 然后基于该位置所在时区提供精确的时间

工具 | 2025.04.16 更新

查看 Higress 配置



黄历/假期助手

创建者: Higress Official

支持中国假期/调休信息查询, 以及中国传统老黄历(择时)查询

阿里云市场 | 2025.04.16 更新

查看 Higress 配置



股票助手

创建者: Higress Official

专为股票、期货及外汇市场设计的多功能服务, 提供了多种工具, 包括K线图、报价、排行等, 以帮助用户获取实时和历史数据, 进行技术分析和决策支持

阿里云市场 | 2025.04.16 更新

查看 Higress 配置



WolframAlpha

创建者: Higress Official

使用WolframAlpha LLM API 与LLM交互, 获取针对大型语言模型使用而优化的结果

工具 | 2025.04.23 更新

查看 Higress 配置

使用 URL 连接 MCP Server

试用 API Key (试用额度每日 100 次)

生成

自定义 API Key

Step 1: 生成 URL

SSE Streamable HTTP

```
{  "mcpServers": {    "mcp-ip-query": {      "url": "https://mcp.higress.ai/mcp-ip-query/"    }  } }
```

Step 2: MCP 客户端一键安装服务 (可选)

DeepChat

一键安装

查看官网

Cherry Studio

一键安装

查看官网

Chatbox AI

一键安装

查看官网

Sire

一键安装

查看官网

LobeChat


查看官网

使用 HiMarket 构建私有 MCP 市场

HiMarket 开源地址: <https://github.com/higress-group/himarket>



使用 HiMarket 构建私有 MCP 市场




Higress API/Ops MCP Server


- Higress API MCP Server 提供了 MCP 工具来管理 Higress 路由、服务来源、AI 路由、AI 提供商、MCP 服务器和插件等资源。
- Higress Ops MCP Server 提供了 MCP 工具来调试和监控 Istio 和 Envoy 组件，帮助运维人员进行故障诊断和性能分析。

04 Demo

MCP Server **快速开始:** <https://higress.cn/ai/mcp-quick-start>



Higress API MCP Server



The screenshot displays the Higress console interface on the left and the Cursor IDE on the right. The console shows the 'Route Configuration' (路由配置) page with a table of routes. The table has columns for 'Route Name' (路由名称), 'Domain' (域名), and 'Route Condition' (路由条件). A single route named 'default' is listed with a domain of '-' and a condition of '精确匹配 | /'. Below the table, a note states '注：列表中仅包含' (Note: only those in the list are included). The IDE shows the 'mcp.json' file with the following configuration:

```
1 mcpServers: {
2   "mcp-github": {
3     "url": "https://mcp.higress.ai/mcp-github/"
4   },
5   "mysql": {
6     "url": "http://10.21.32.14:80/mysql/sse"
7   },
8   "higress_ops_mcp": {
9     "url": "http://127.0.0.1:80/higress-ops/ss
10    "headers": {
11      "X-Istiod-Token": "eyJhbGciOiJIUzU1NiIsI
12    }
13  },
14  "higress_api_mcp": {
15    "url": "http://127.0.0.1:80/higress-api/ss
16    "headers": {
17      "Authorization": "Basic YWRtaW46YWRtaW4=
18    }
19  },
20  "amap-amap-sse": {
21    "url": "https://mcp.amap.com/sse?key=f9719
22  },
23  "daxt": {
24    "url": "http://127.0.0.1:80/mcp-servers/da
25  },
26  "kubectl-ai": {
27    "command": "/usr/local/bin/kubectl-ai",
28    "args": ["--kubeconfig", "~/.kube/config",
29    "env": {
30      "KUBECTL_AI_MCP_SERVER": "http://10.24.2
31  }
32 }
```

The IDE also shows a '调用 envoy debug 配置 httpbin.org 的 HTTPS 路由' (Call envoy debug configure https route of httpbin.org) window with the text '配置一个到 httpbin.org 的路由, https' (Configure a route to httpbin.org, https) and '路由匹配前缀是 /' (Route matching prefix is /). The IDE status bar at the bottom indicates 'Cursor Tab Ln 32, Col 8 (4 selected) Spaces: 2 UTF-8 LF {} JSON with Comments'.

Thanks



Se7en

上海 浦东新区



扫一扫上面的二维码图案，加我为朋友。



Se7en的架构笔记 ♂

UID: 57740635

