

蚂蚁大规模Kubernetes服务在数智 时代的突破与重构

谭 崇 康 （ 见 云 ）

蚂蚁集团高级技术专家

2025/11/15





谭崇康（见云）

蚂蚁集团高级技术专家

个人简介：蚂蚁集团容器平台团队，负责容器实例与Kubernetes服务，主导了蚂蚁大规模Kubernetes集群架构设计，在云原生及基础计算平台领域有丰富的工作经验。

CONTENT

目录

- 01 在数智快车上，K8s承担什么角色
- 02 数智应用的K8s服务需要满足什么特性
- 03 怎样建设一个与之匹配的K8s服务
- 04 一些实践经验

几个不惊讶但依旧激动人心的数据

数智应用飞速发展，K8s是其中的重要组成部分

智能应用在飞速发展

截止2025年7月，已发布大模型数量

1509 / 3755

Unique new insights into the trends driving enterprise cloud native today



90% Expect to run more AI workloads on Kubernetes in the next 12 months. AI is the top growth trend.

88% Reported increased Kubernetes TCO year on year. Cost is the #1 challenge facing adopters.

50% Now run Kubernetes in production at the edge, driven by AI workloads.

51% Still run clusters as 'snowflakes' with highly manual operations, despite 80% adopting platform engineering practices.



Get the report at:
bit.ly/sopk2025

从常用的AI应用框架，我们能看到什么

AI应用框架如何与K8s交互

框架	核心研发语言	K8s 适配方式	核心定位
TensorFlow	C++（底层）、Python（API）	TensorFlow Operator	通用深度学习（训练 + 推理）
PyTorch	C++（底层）、Python（API）	PyTorch Operator	灵活深度学习（科研 + 工业）
Kubeflow	Go（核心）、Python（SDK）	原生 K8s CRD/Operator	AI 工作流编排（CNCf 孵化）
MLflow	Python（核心）	Docker 镜像 + K8s 部署	ML 生命周期管理
Ray	C++（底层）、Python（API）	Ray Operator	分布式 AI 计算（CNCf 沙箱）
Horovod	C++（核心）、Python	适配 Kubeflow/Operator	多框架分布式训练
KFServing	Go（核心）、Python	InferenceService CRD	云原生推理服务（Kubeflow 生态）
TorchServe	Java（核心）、Python	Deployment/Helm	PyTorch 官方推理服务

框架




Operator

研发这些AI框架Operator的工程师真的非常了解如何面向Kubernetes的编程吗？

一些“哭笑不得”的设计和使用问题

Kubernetes远不是一个0成本使用的服务

- 1 不合适的编码模式造成性能退化
- 2 不合适的选主配置导致丢主频繁
- 3 遇到故障机导致不能处理时间
- 4 性能问题导致消息处理延迟
- 5 不合适的处理逻辑阻塞处理线程
- 6 缺乏分片机制导致资源占用大FO困难
- 7 缺乏计算索引导致处理性能低等等



- 1 API限流及返回失败容忍
- 2 不合适的请求模式导致请求延迟长
- 3 资源数量/大小超出集群限制, 导致服务无法正常工作
- 4 针对证书权限等缺乏持续的观测运维能力, 导致证书过期等异常

- 1 缺乏错误处理逻辑, 导致业务逻辑处理异常
- 2 非面向终态设计, 导致在特性逻辑下丢失消息, 影响业务逻辑正确性
- 3 业务处理逻辑性能差, 处理线程配置不合理, 导致持续性队列增长
- 4 缺乏对多级缓存的时延处理及校验机制, 导致业务处理逻辑异常

基础设施如何让这辆赛车更富竞争力

建设更加适合数智应用执行的Kubernetes服务

Meta宣称在训练OPT-175B模型的在两个星期的时间段内因为硬件、基础设施或实验稳定性问题而重新启动了35次。

在开放的日志中也可以看到，几乎整个训练过程都要面对不停地重启和中断。

<https://arxiv.org/pdf/2205.01068>



为数智应用这些赛车们做好 **基建和轮胎**


图片由AI生成

CONTENT


目录

- 01 在数智快车上，K8s承担什么角色
- 02 数智应用的K8s服务需要满足什么特性
- 03 怎样建设一个与之匹配的K8s服务
- 04 一些实践经验

卡+应用规模+效率竞争影响集群规模



模型竞速



算力供应



<https://cloud.google.com> › [blog](#) › [products](#) · [翻译此页](#)

Google Kubernetes Engine supports 65000-node clusters

2024年11月14日 — With support for 65000-node clusters, **Google Kubernetes Engine** offers more than 10X larger scale than the other two largest public cloud ...

稳，再稳一些，别添乱

一些被热烈讨论的友商故障

- **2025 年 AWS 大规模故障致 AI 平台中断**：2025 年 10 月 20 日，亚马逊云服务（AWS）美国东海岸数据中心发生大规模故障，故障源于 AWS 美东一区（US-EAST-1）的 DNS 解析问题，导致全球数千个网站和应用程序服务中断长达数小时。此次事件影响范围广泛，包括 ChatGPT、Perplexity 等 AI 平台。其中，OpenAI 的 ChatGPT 出现单点登录（SSO）问题，用户无法正常登录使用；AI 搜索引擎 Perplexity 也因 AWS 问题出现宕机。
- **2024 年 OpenAI 因 Kubernetes 监控服务故障导致服务中断**：2024 年 12 月 11 日，OpenAI 旗下 AI 聊天机器人平台 ChatGPT、视频生成工具 Sora 及其面向开发人员的 API 发生严重中断。OpenAI 事后报告显示，此次宕机是新部署的用于收集 Kubernetes 指标的监控服务所引发，该监控服务的配置无意间导致资源密集的 Kubernetes API 操作，使得 Kubernetes API 服务器不堪重负，多数 Kubernetes 集群中的控制平面陷入瘫痪，最终耗费约三个小时才恢复所有服务。
- **2024 年微软数据中心电力故障致 ChatGPT 服务中断**：2024 年 12 月 27 日凌晨 2 点 30 分左右，OpenAI 旗下的 ChatGPT 再次遭遇严重的服务器故障，同时影响到 Sora 视频生成模型以及部分 API 调用。OpenAI 在其官方状态页面确认系统出现高错误率，经过近三小时的修复，ChatGPT 于早上 6 点 05 分部分恢复，但聊天历史记录的加载问题依旧存在。OpenAI 称问题由上游提供商引起，而其独家云服务提供商微软 Azure 证实数据中心出现了电力问题，此次故障很可能是由此导致。

为赛车搭配合适的基建和轮胎

做好一个匹配智算应用计算需求的Kubernetes服务


抓地力 排水性 强度 温度



图片由AI生成

重量
阻力
均衡性
其他

弹性 成功率 诊断自愈 资源供应



规模
性能
其他



CONTENT

目录

- 01 在数智快车上，K8s承担什么角色
- 02 数智应用的K8s服务需要满足什么特性
- 03 怎样建设一个与之匹配的K8s服务
- 04 一些实践经验

怎样让大规模集群“稳”：可以是大象，但是不能臃肿

稳定=规范管控+合理的饱和度+故障自愈

— 规范管控


- KoM架构、多维度精细化限流
- 统一接入标准化管控

— 合理的系统饱和度

- 内存降低50%，CPU降低30%，ETCD存储水位降低20%
- 请求吞吐提升 40%


— 完善的自愈能力

- Controller自愈，节点自愈



怎样让大规模集群“稳”：服务托管

KCS (K8sControllerStack) 让Controller编程更简单



KCS ControllerRuntime版本


WarmCache、长尾请求管理、主动感知故障/主动自愈、观测诊断等技术

- 切主耗时 10min → 10s
- Watch延迟 P99 < 1s
- 请求成功率 99.9%



怎样让大规模集群“稳”：独立执行环境

应用Cell化管理，应用独立执行互不干扰



CELL化独立的执行环境，提供混布集群更高用户隔离能力

- **ApiResourceLimiter**: 对ApiServer的API请求Quota，包含用户请求以及系统为用户提供服务发起的请求。
- **ResourceCell**: 用户资源视图。保障平台方只能看见平台方自己创建的资源。
- **ETCDStorageLimiter**: 可以使用的ETCD存储对象的个数和大小。
- **SystemCapacities**: 独立的系统功能，例如调度、DNS、网络模式等。

如何让大象也能跳舞：极速API链路


高速K8s API链路

MVCC ReadCache/NPKV/动态索引等优化

— ETCD性能读延迟P99降低 51%，写延迟P99降低 32%


— ApiServer 吞吐提升30%+，Event 降低90%+，Watch延迟P99 < 1s

— Controller CPU利用率降低 50%+，Memory降低66%，Watch延迟降低P99 <1s



如何让大象也能跳舞：极速容器弹性链路

KubeSpeed容器极速交付链路




KubeSpeed容器加速技术，支持
Sandbox、镜像、Pod缓存等多维
加速能力

— 应用启动耗时降低 95%

怎样让大集群更适合智算：容器交付保障

TKP(TurnKeyResourceProvision)容器交付托管



TKP容器托管技术支持容器
(Workload) 创建、删除托管


- 创建成功率提升 2%
- 删除成功率提升 3%
- 大幅节省创建/删除过程中的计算卡时浪费

怎样让大集群更适合智算：资源供应保障

TKP大规格及跨集群资源交付托管

TKP大规格ReplaceQuota技术及
化集群交付技术

- 大规格耗时长Pod比例降低90%
- 支持丰富的多集群资源供给能力




怎样让大集群更适合智算：问题诊断及自愈

Lunettes E2E容器自助诊断服务

端到端的诊断到自愈链路，L1 拦截率提升至80%+

- Log/Event/Audit等多维度数据构建端到端的问题诊断能力
- 应用、模型、容器、SLO等全域场景支持
- Metrics、Trace的各种形式下钻能力
- 打通诊断+自愈全链路，提升用户自助能力



CONTENT


目录

- 01 在数智快车上，K8s承担什么角色
- 02 数智应用的K8s服务需要满足什么特性
- 03 怎样建设一个与之匹配的K8s服务
- 04 一些实践经验

和社区站在一起

收益项	具体说明
安全性提升	社区修复大量漏洞，加强 RBAC、Webhook、Secret 等安全措施，有效降低安全风险
新功能与优化	新版本支持更多高级功能，如 DRA、网络策略、资源扩展、服务网格等
性能与稳定性提高	控制面和调度器更优化，节点和负载管理性能提升
第三方生态兼容性提升	与主流 DevOps、监控、服务网格等工具插件全面兼容，可用新版本生态插件
运维便利性提高	更完善的集群管理资源、调优参数、自动运维特性提升
更长生命周期与支持	新版本获得社区和第三方长期支持，降低技术债务和维护压力


聚沙成塔，造就不同



6 -> 12 -> 24 -> -> 24576



2 -> 7



1000年

感谢大家

**We're hiring
Join us**

欢迎加入我们