

从云原生到 AI 原生： 模型引发的新一代基础设施构建

余锋（褚霸）


蚂蚁集团
基础设施技术委员会主席
超级计算技术部负责人



01

基础设施技术的演进


软件定义基础设施之始：虚拟化与云计算



容器与云原生：应用为中心



云原生：良好架构带来的生态繁荣



02 GenAI 时代的应用

模型成为新的数据库

GenAI 之前的（互联网）应用 Pattern

LAMP 的演进之路

数据库是应用系统的核心


大规模分布式数据库、数据中间件等，帮助构建高性能大规模应用。数据库是核心的应用基础设施。

面向互联网规模的复杂应用

消息队列、服务发现、RPC、应用框架等（Spring），用于构建大规模并行应用；云原生时代，引入了 ServiceMesh（istio）、AppRuntime（dapr），将应用和应用基础设施解耦。

数据计算链路


在线服务之外，服务过程产生的数据，会进入数据计算链路，进行离线或实时计算，构成数据驱动的应用。



open source closed source
 <100B 100B - 999B ≥1000B unpublished

Large Models Landscape 2025

ANT OPEN SOURCE ANT INCLUSION AI



生态位的变化：模型在成为新的数据库

财报信息提取

主要会计数据	2021年
营业收入	14,603,100,739.78
归属于上市公司股东的净利润	1,227,372,820.22
归属于上市公司股东的扣除非经常性损益的净利润	1,209,084,450.63
经营活动产生的现金流量净额	3,426,414,563.66

报表信息校验



金融数值计算



分析师角色指令



金融逻辑校验



公司点评报告

年度点评

一、公司概况

宜宾五粮液股份有限公司（以下简称“五粮液”）是一家以白酒生产和销售为主的上市公司，成立于1998年，总部位于四川宜宾市。该公司主要从事白酒生产和销售，旗下拥有多个知名品牌，包括五粮液、五粮春、五粮醇、五粮特曲、尖庄等。2022年，公司实现营业收入739.69亿元，同比增长11.72%，实现利润总额371.04亿元，同比增长14.34%。五粮液的产产品结构持续优化，推出了多款新品，加强了品牌运营和文化建设，同时在营销变革、科技创新和布局长远方面取得了重大进展。

二、财务分析

1. 营业收入和成本分析

2022年，五粮液的营业收入为739.69亿元，同比增长11.72%，其中酒类产品营收占比91.34%，五粮液产品营收占比74.81%，其他酒类产品营收占比16.53%。五粮液的毛利率为86.56%，其他酒产品的毛利率为60.07%。公司的销售模式主要是经销模式，占比54.74%，直销模式占比36.60%。公司的主要销售客户为经销商，前五大客户的销售额占销售收入的13.25%。

2. 费用分析

2022年的销售费用为6.84亿元，同比增长5.24%，其中形象宣传费、促销费、仓储费及物流费、人工费用和其他费用分别为18.12%、56.83%、6.97%和7.59%。公司的研发投入为235.78万元，主要用于生产工艺等科研项目，同比增长32.90%。

3. 现金流分析

2022年的经营活动现金流入小计为83,849,102,992.33万元，同比增长0.99%，经营活动现金流出小计为59,417,966,730.85万元，同比增长5.63%，投资活动现金流入小计为69,705,342.99万元，同比增长45.51%，投资活动现金流出小计为1,786,159,893.52万元，同比增长15.63%，筹资活动现金流入小计为13,105,431,458.20万元，同比增长16.29%，筹资活动产生的现金流量净额为-1,716,454,550.53万元，同比下降31.40%。

4. 资产和负债情况分析

2022年底，公司的货币资金为92,358,426,975.79万元，占总资产的60.48%，应收账款为35,686,942.32万元，占总资产的0.02%，存货为15,980,657,013.57万元，占总资产的10.46%，长期股权投资为1,986,387,324.78万元，占总资产的1.30%，固定资产为5,312,971,445.61万元，占总资产的3.48%，在建工程为3,773,155,983.95万元，占总资产的2.47%，使用权资产为380,922,885.84万元，占总资产的0.25%。公司的现金及现金等价物净额增加额为9,609,386,518.94万元，同比下降31.40%。

5. 投资状况分析

2022年，公司未进行重大股权投资和衍生品投资，但进行了多项非股权投资，包括信息化建设、营销中心建设、成品酒包装及智能仓储一体化、勾调酒库技改工程等项目。

6. 公司治理情况

2022年，公司完成了第六届董事会的换届选举，并成立了战略、审计、提名、薪酬与考核、全面预算管理等五门专门委员会。公司的董事、监事、高级管理人员薪酬由董事会薪酬委员会审核通过，按月发放部分基本薪酬，年度内发放部分绩效薪酬。

7. 员工情况

2022年底，公司共有员工25,464人，其中生产人员19,081人，销售人员1,145人，技术人员4,048人，财务人员198人，行政人员992人。公司实施了员工持股计划，并通过“非交易账户”方式过户给持有人证券账户。

8. 社会责任情况

2022年，公司积极参与扶贫工作，在理塘县和屏山县开展了一系列帮扶项目，包括基地建设、消费帮扶、党建引领和乡村治理等，并获得了多项荣誉。此外，公司还注重绿色发展，确保就业稳定，并积极推进产教融合。

三、风险提示




👉一个基于多 Agent 的财报解读应用（例中应用基于 AgentUniverse 框架构建）

越来越多的应用，使用模型生成的内容来服务用户，而不是基于数据库来生成内容。GenAI 时代的大模型正在充当 Web 2.0时代的数据库的生态位，这会对基础设施需要满足的需求，和它的架构带来很多变化。

03


模型为中心的基础设施

开源模型推理引擎 vLLM 和 SGLang 快速崛起



两个项目成长迅速，不仅性能竞赛一直在持续，而且都有上千开发者，开发速度都很快，大量的 Issue 会在几个小时内就得到响应。任何单一一家公司都很难跟上社区的脚步。

模型的优化部署与服务




大模型应用的请求与数据库应用的模式不同，每个请求的计算消耗量大，且请求之间差异很大，需要整个基础设施的系统化适应和改进，而不仅是推理引擎本身的优化。

LLM-d 等项目同样是在处理这个系统问题。


模型的规模化服务，以开源的蚂蚁 AIGW + Mooncake 为例

更进一步，从云原生到 AI 原生，从应用为中心到模型为中心



From CNCF Sandbox Project ModelPack (<https://github.com/modelpack/model-spec>)

借助已有的云原生生态，将开放接口、开放标准、不可变基础设施的理念，与大模型的生命周期管理与优化部署结合，帮助构建更高效的模型开发与服务生态




04

AI 应用的基础设施


或者说，Agent 基础设施

Agent 领域开源项目的活跃度趋势


AI Coding




Chatbot



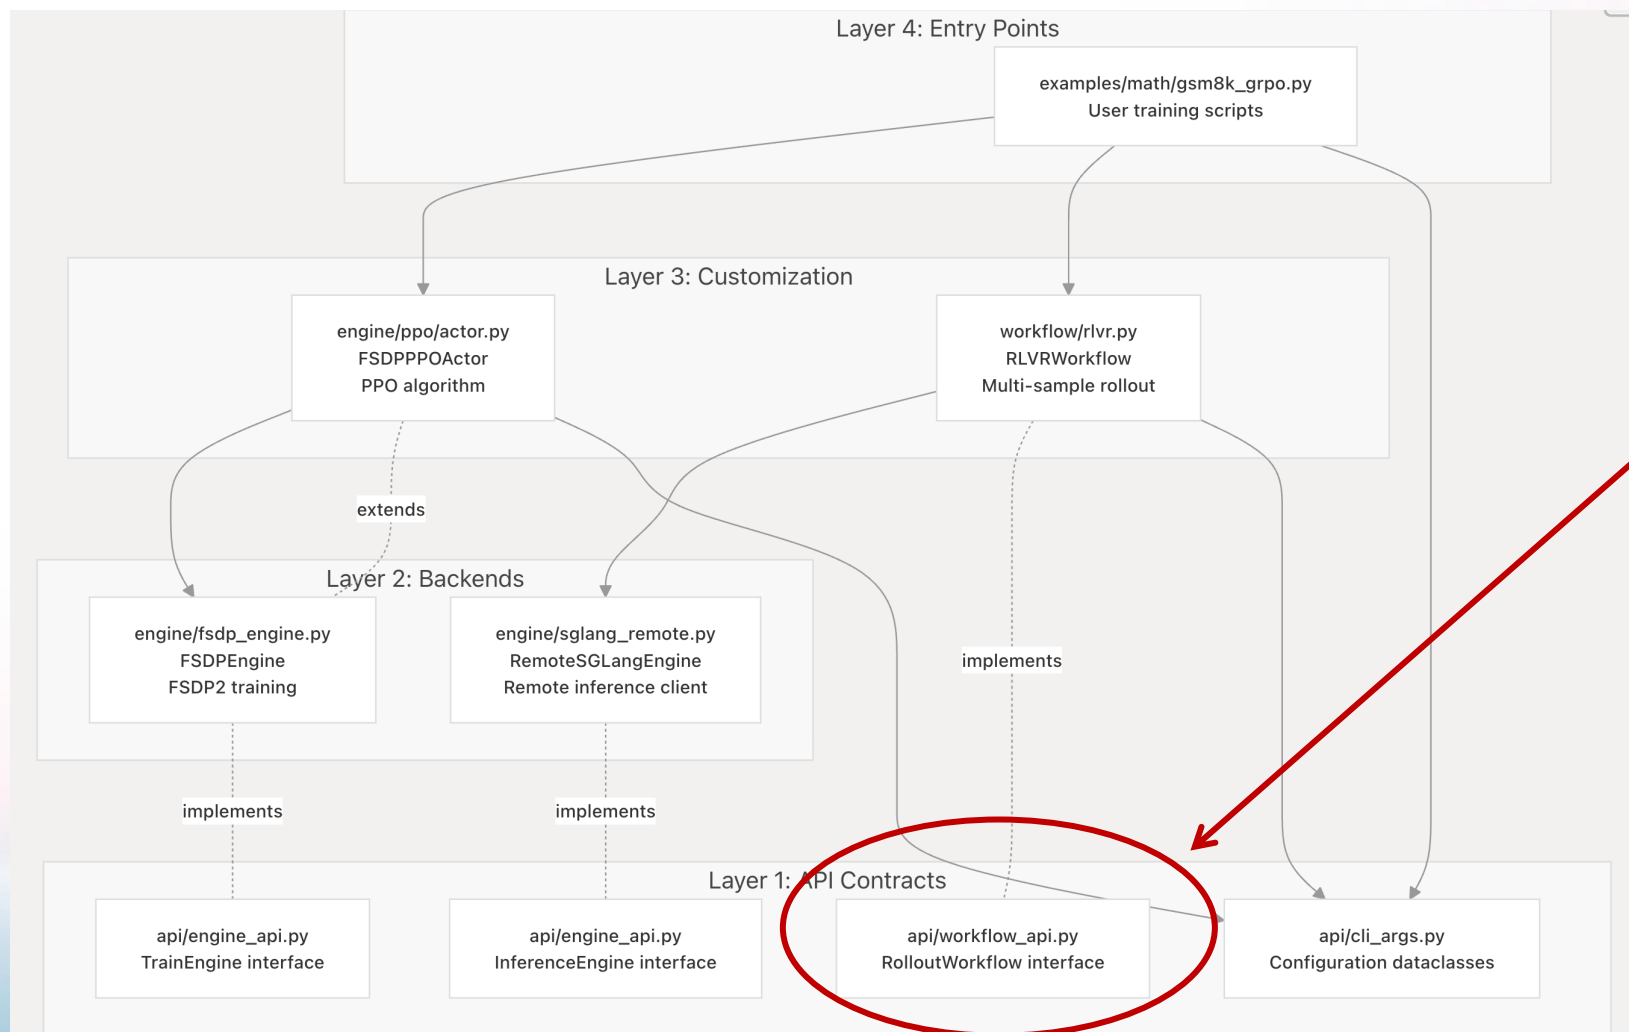
Agent Framework



Agent Workflow platform



同样，模型训练也在引入 Agentic RL



以 inclusionAI/AReal 项目为例，作为一个强化学习框架，在 ARealite 版本中增强了 Agentic RL，通过 Agent，来提升模型的泛化能力。

这样任意定义/引入的 Agent 代码，在训练过程中被执行，给基础设施也提出了更多需求

Agent Sandbox 与 Agent Tools

一切都是Agent，未来可能需要有海量的 Agent 和运行它们的 Sandbox，给已有的 Sandbox 技术和平台带来了新的挑战 and 机会



功能性

从简单的计算器，到搜索，再到浏览器、Computer Use，乃至执行任意代码，都可能是 Agent 或 Agent Tools 需要完成的功能



性能与并发量

对于 Agentic RL，可能需要同时并发执行大量的 Agent，并要求响应速度很快，镜像和容器加速项目都可能会被用到



Sandbox 的隔离性

因为 Agent 有可能执行任意获取的代码，或者是模型生成的代码，因此需要使用安全容器或其他安全的配置，来保护基础设施，免受意外或恶意的攻击，Kata Containers, Firecracker, gVisor, 都是被大量提到的沙箱技术。

05 展望

从“通算+智算”向通智一体的演进

从“通算+智算”向通智一体的演进

很多前 AI 时代的应用也将向 Agent 演进，Agent 也会做一些“普通”的工作

挑战：

- 「基础设施的稳定性」与「模型技术的快速变化」的矛盾，工程质量的保障需要被更有效地关注；
- 如上提到的 Agent 的任意执行可能，会引发更多的安全和滥用风险，需要谨慎地解决或防御这些问题

应对或机遇：

- 我们有机会在这样的变革来临时，和应用一起进步，构建更好的 CloudNative AI，或者是 AI-Native 架构；
- 我们已经有的沙箱技术可以帮我们应对安全威胁；
- 利用 AI 本身的发展，也可以帮助我们更好地、智能地应对这些风险和挑战。

THANKS

大模型正在重新定义软件（以及硬件）

Large Language Model Is Redefining The Software and More

