



多网卡容器网络加速离线训练的实践

张荣 & 欧锡培 @vivo互联网





Content 目录

- 01** 背景和挑战介绍
- 02** 如何使用RoCEv2构建离线训练K8s集群
- 03** 训练任务加速比收益测试
- 04** 基础设施网络设计



Part 01

背景和挑战介绍

训练任务管理

业务场景

应用商店、浏览器、游戏中心等业务场景的广告和推荐



AI应用场景语音识别、图像算法优化、vivo千询

数据收集、加工、标注、存储

训练框架



PyTorch



任务创建

选择训练框架/多集群资源分组

训练环境参数封装

初始化指定训练数据

资源调度

Gang调度、预选、优选

异构资源GPU

异构高速网络
RDMA资源 (IB、RoCEv2)

任务管理

日志/监控


job

启动/终止
/exec

异常/容错

训练平台训练任务管理

RDMA(Remote Direct Memory Access)




远程直接内存访问（ Remote Direct Memory Access , RDMA ）是一种绕过远程主机操作系统内核访问其内存中数据的技术，由于不经过操作系统，不仅节省了大量CPU资源，同样也提高了系统吞吐量、降低了系统的网络通信延迟，尤其适合在大规模并行集群中有广泛应用。

Job：K8s的job，用于离线任务的生命周期管理。

data：离线训练数据集，主要存储在分布式存储HDFS里，训练启动时会拉取数据加载到内存里。

RDMA技术选型




RDMA类型

类型	IB	iWARP	RoCEv2
性能	高	中	基本和IB相当
成本	高	中	低
稳定性	高	差	中
交换机	IB专用交换机	以太交换机	以太交换机

协议对比

- Infiniband协议,一整套完整的链路层到传输层规范，无法复用已有以太网设备，需要购买全部Infiniband设备
- ROCE协议,基于以太网层的协议,可以复用已有的以太网设备,其中RoCEv2基于UDP实现
- iWARP协议, 相比于RoCE 和IB具有更好的可靠性，但会耗费很多内存资源，基于TCP实现

基于IB构建的AI训练集群



业务场景：

- AI应用场景语音识别、图像算法
- 大模型场景


现状：

- 基于K8s+Infiniband网卡构建AI集群
- 使用DP-RDMA插件上报RDMA资源
- 架构简单，运行稳定
- IB不依赖传统的网络软件栈，基于OpenSM、LID完成寻址与通信

挑战：

- 单台节点上训练pod和网卡数量一致，可能资源浪费
- IB+SRIOV和IB+Macvlan方案未来探索的方向

基于TCP构建的离线训练集群



业务场景：

- 应用商店、浏览器、游戏中心等业务场景的广告和推荐
- 训练时间较短，小时计算

现状：

- 基于Calico BGP+RR网络构建离线训练集群，训练效率低
- 无法基于Infiniband构建集群成本高，收益小
- 当前主要用cpu资源训练，资源紧张，任务排队等情况
- 随着业务数据量和业务增加，对高带宽/低延迟网络有需求

挑战

- 需要构建低成本、稳定的、无损的RoCEv2(RDMA over Converged Ethernet)网络，提高训练效率
- 通过RDMA协议，降低cpu消耗，增加训练任务量
- 需要解决网卡可以虚拟出来多个子接口/网卡和根据RoCE物理网络设计下的复杂场景的ip分配，同理就可以解决IB基于HOST Device方案存在的挑战



Part 02

如何使用RoCEv2构建离线训练K8s集群

RoCEv2方案

容器单网卡Sriov方案

开源组件实现：

- SRIOV-DP
- IPAM(whereabouts)
- Sriov CNI

存在的问题：

- 不能保证 POD 和宿主机的连通性，导致应用访问 clusterIP、应用健康检测、IP冲突检测、网关可达等，需要修改k8s组件实现。

容器双网卡Calico+Sriov方案

开源组件实现：

- SRIOV-DP
- IPAM(Whereabouts)
- Calico
- Sriov CNI
- Multus

存在问题：

- VF掉卡，VF卡限制
- 复杂物理网络场景IP分配

容器双网卡Calico+Macvlan方案

开源组件实现：

- k8s-rdma-shared-dp
- IPAM(Whereabouts)
- Calico
- Macvlan CNI
- Multus

存在问题：

- 可能存在子接口性能问题
- RDMA设备共享
- 复杂物理网络场景IP分配

SRIOV-DP和CNI: <https://github.com/k8snetworkplumbingwg/sriov-network-device-plugin>

whereabouts: <https://github.com/k8snetworkplumbingwg/whereabouts>


Multus: <https://github.com/k8snetworkplumbingwg/multus-cni>

Calico: <https://github.com/projectcalico/calico>

K8s-rdma-shared-dp: <https://github.com/Mellanox/k8s-rdma-shared-dev-plugin>

Macvlan: <https://github.com/containernetworking/plugins/tree/main/plugins/main/macvlan>

容器双网卡Calico+Macvlan方案



Calico:

集群的默认网络,用于 Pod 之间的通信和访问 Kubernetes API Server。



Macvlan+Spiderpool:

构建离线分布式训练数据计算网络，Macvlan 通过 eth1网口创建多个虚拟网络，每个虚拟网络都有自己的 MAC 地址和 IP 地址，可以独立于其他虚拟网络进行通信，Spiderpool根据网络规划设置不同资源池，自动分配net1的ip地址并保证全局唯一。

k8s-rdma-shared-dev-plugin:

用于识别网卡，在pod创建时将eth1对应的RDMA网络设备挂载到容器里，业务通过访问容器内的RDMA设备进行网络通信。

Multus CNI




Multus CNI

- 支持多种网络接口，如Calico，Macvlan，Sriov
- 将多个网络接口绑定到一个Pod中

RDMA NetWork：训练任务之间数据通信
Cluster NetWork：集群服务发现

IPAM : SpiderPool



CNI :

- 创建Macvlan子接口
- IPAM配置IP/Mac , CIDR , GateWay , Route


Spiderpool: <https://github.com/spidernet-io/spiderpool>

```
apiVersion: spiderpool.spidernet.io/v2beta1
kind: SpiderIPPool
metadata:
  name: xxxx
spec:
  subnet: 192.168.19.0/25
  ips:
    - 192.168.19.1-192.168.19.124
  gateway: 192.168.19.126
  routes:
    - dst: 192.168.16.0/20
      gw: 192.168.19.126
  nodeAffinity:
    matchExpressions:
      - key: kubernetes.io/hostname
        operator: In
    values:
      - xxxx
```

SpiderPool(Underlay CNI场景IP分配解决方案) :

- 社区提供的IPAM , 如DHCP , host-local , Static , WhereAbouts 无法满足要求 , SpiderPool完全可以适配RoCE物理网络设计
- 可以解决IP冲突 , 设置subent , routes , gateway
- 可以预留IP给物理机网卡使用 , 如192.168.19.125给物理机使用 , 192.168.19.126作为网关 , 192.168.19.1-192.168.19.124为该节点地址范围
- 可以根据物理网络拓扑 , 设置节点亲和分配IP

RDMA Device plugin



k8s-rdma-shared-dev-plugin:

- 主要用于网卡资源上报，和网卡挂载到pod
- 特殊网卡无法识别，需要修改代码才能上报资源

业务pod如何使用RoCEv2

```
apiVersion: apps/v1
kind: Deployment
metadata:
labels:
  app: rdma-test
  name: rdma-test
selector:
  matchLabels:
    app: rdma-test
template:
  metadata:
    annotations:
      k8s.v1.cni.cncf.io/networks: default/macvlan-net
  spec:
    containers:
      image: xxxx/rdma-rping:v1.0.0
      name: rdma-test
    resources:
      limits:
        vivo/rdma: "1"
    securityContext:
      capabilities:
        add:
          - IPC_LOCK
```

K8s 资源改造

Brpc RDMA

介绍：

- Brpc的含义是“better RPC”，百度开源的项目。
- Brpc是用c++语言编写的工业级RPC框架，常用于搜索、存储、机器学习、广告、推荐等高性能系统。
- 支持RDMA协议，Brpc内部实现了静态内存池，优化了数据传输零拷贝，数据传输有滑动窗口流控，数据传输逻辑的第三个重要特性是事件聚合。

服务端：

-rdma_device	指定RDMA设备net1
-rdma_gid_index	指定RDMA设备的索引为2
-use_rdma	true 为RDMA，默认TCP
-port	指定监听端口


客户端：

-rdma_device	指定RDMA设备net1
-rdma_gid_index	指定RDMA设备索引为2
-use_rdma	true 为RDMA，默认TCP

Brpc：<https://github.com/apache/brpc>

业务框架Brpc改造

业务迁移到RDMA网络区域






Part 03

训练任务加速比收益测试

测试环境和工具





RDMA性能测试集群



协议	工具	版本
RDMA	perftest	6.13
TCP	qperf	0.4.9

网卡	服务器	型号
mellanox	node3/node4	ConnectX-4
intel	node1/node2 node5/node6	E810

K8s-RDMA vs 物理机




RDMA vs TCP—带宽和时延




网卡性能测试

A B表示为不同厂家网卡



离线任务加速比



结论：


- 使用RDMA后，训练时间加速比正相关。
- intel和mellanox网卡基于当前框架可以混合跑业务。
- 当前主要是测试集群计算资源出现瓶颈，带宽使用只有真实带宽的一半，仅供参考。



Part 04

基础设施网络设计

物理网络拓扑



容器控制网络 (TCP) :

服务器管理流量、容器调度流量、存储数据流量

容器集群:

双臂架构：eth0-接入TCP、eth1-接入RoCE_V2

调度平面与计算平面分离：

存储流量无法抢占RoCE计算网络资源、

可通过调度平面登录并隔离异常设备

双网卡方案：PF相对VF更稳定、二开成本更低

容器计算网络 (RoCE_V2) :


容器训练流量

spine-leaf-二层CLOS架构：避免跳数过多延时过高

BGP+ECMP：多链路负载均衡、流量均衡哈希

1:1收敛比：无阻塞网络架构、IN=OUT

网络路由设计



Calico+MACVLAN双CNI

Calico侧

Overlay-CNI：可复用CNI自身丰富的网络功能、基于BGP路由发布

Macvlan侧

Underlay-CNI：性能高（时延、吞吐量优于overlay）、对接VLAN网络

单台Node独占一个网段：

物理方式隔离广播域、故障域细粒度

ARP广播小、容器无效计算资源损耗较少

容器macvlan接口不需要打vlan标签、理论延时更低


POD多网卡路由调谐

Calico：通过默认路由调度出局

Macvlan：通过明细路由参与计算

保证数据请求向和回复向路径一致

网络瓶颈




离线训练：MAP/REDUCE循环过程

- 1、MAP：将训练任务分解成多个子任务，每个子任务分发给计算节点处理
- 2、REDUCE：搜集多个计算节点的处理结果，进行汇总，汇总过程产生Incast流量
- 3、Incast特征：N台服务器传输数据给同一台服务器的流量，容易导致网络拥塞从而丢包
集群越大、N值越大、网络拥塞丢包可能性越高

网卡带宽

增加服务器网卡可以缓解问题、但不能彻底解决问题，不加限制下网卡带宽终究会消耗殆尽。因此需要有一个机制解决网络拥塞问题，保证RoCE应用零丢包的无损网络环境

无损网络实现



比较项目	ECN	PFC
层级	网络层	二层
生效范围	端到端	逐跳提供
降速对象	客户端	上游节点
降速效果	源端降低发送速率	上游停止发送
目的	网络拥塞减缓	不影响其他优先级报文

ECN/PFC搭配使用


ECN 显式拥塞通知

一种端到端拥塞通知机制，通过IP报文DS域标记网络链路拥塞情况，通知发送端降低报文发送速率，保证网络吞吐平稳、降低整体延时

PFC 基于优先级的流量控制

设备基于报文标记优先级调度转发，当拥塞发生时，发送pause帧让上游设备暂停一段时间发送流量，保障整体网络无丢包

ECN



ECN域


IP报文DS域后2个比特组成ECN域

ECT位：标记是否支持ECN功能



CE位：标记是否拥塞

ECN交互过程

- ①客户端发送IP报文（支持ECN功能）
- ②交换机队列拥塞时收到该报文、将ECN字段标记为11（网络拥塞）并发出、网络中其他交换机正常转发该报文
- ③服务端收到该报文，发现网络拥塞，正常处理该报文
- ④服务端发出拥塞通告，发送CNP报文（ECN字段标记为01），要求报文不被网络丢弃
- ⑤交换机收到CNP报文后正常转发该报文
- ⑥客户端收到ECN标记为01的CNP报文后，降低对应流应用速率



PFC



PFC交互过程

- ①交换机一本地队列触发缓存门限，往流量上游发送PFC PAUSE帧
- ②交换机二收到PAUSE帧，对相应队列报文进行缓存，直到触发门限后，继续往上游设备发送PAUSE帧
- ③交换机三收到PAUSE帧，对相应队列报文进行缓存，没有触发门限，不对上游设备发送PAUSE帧

基于优先级的流量控制

- ①服务器
RDMA应用报文：标记DSCP优先级40
- ②交换机
完成DSCP优先级、dot1p优先级、本地优先级、本地队列映射
通过队列5发送RDMA应用报文、并通过pause帧降低上游设备报文发送速率

Thanks.



vivo互联网技术

